

API SentimentalBanking: Correlação Funcional e Priorização de Backlog em Apps Bancários via Inteligência Artificial Híbrida

Simone Rossetti Nobre Naxara^{1*}; Dra. Anna Carolina Martins²

² Técnica em Redes de computadores pelo Senac, Economista graduada pela Unimontes, Mestre em Economia Aplicada pela Universidade Federal de Ouro Preto (UFOP) e doutoranda em Economia na área de Teoria Econômica na Unicamp. São Paulo, SP, Brasil.

*autor correspondente: simone-rossetti@usp.br

API SentimentalBanking: Correlação Funcional e Priorização de Backlog em Apps Bancários via Inteligência Artificial Híbrida

Resumo

O monitoramento da satisfação do usuário em aplicativos bancários é crítico para a retenção de clientes, mas o volume massivo de avaliações não estruturadas dificulta a identificação ágil de falhas técnicas. O objetivo deste trabalho foi desenvolver uma API de correlação funcional que automatiza a classificação de reviews e a priorização de backlog. Diferente de abordagens tradicionais focadas apenas na polaridade, a solução proposta utiliza uma arquitetura híbrida: o modelo XLM-RoBERTa para análise de sentimentos e o LLM GPT-4o para categorização semântica das funcionalidades (ex: Pix, Biometria). O estudo de caso utilizou dados recentes (janela de 90 dias) dos aplicativos Santander e Bradesco na Google Play Store. Os resultados preliminares demonstram que a solução é capaz de identificar picos de reclamações associados a versões específicas dos aplicativos, gerando insumos acionáveis para as equipes de desenvolvimento e reduzindo o tempo de resposta a incidentes críticos.

Palavras-chave: Mobile Banking; Análise de Sentimentos; Priorização de Backlog; NLP; LLM.

Introdução

A transformação digital do setor financeiro consolidou os aplicativos móveis como o principal canal de relacionamento bancário no Brasil. Segundo a FEBRABAN (2024), o mobile banking é responsável por mais de 75% das transações realizadas no país. Nesse cenário de alta dependência tecnológica, a experiência do usuário (UX) torna-se o diferencial competitivo primordial.

As lojas de aplicativos (Google Play e Apple Store) funcionam como termômetros em tempo real dessa experiência, acumulando um vasto volume de Big Data textual não estruturado. Para instituições financeiras, gerir eficazmente essas informações é vital não apenas para a satisfação do cliente, mas para a eficiência operacional (Anouze et al., 2019). No entanto, o monitoramento manual ou baseado apenas em métricas quantitativas (nota de 1 a 5 estrelas) mostra-se insuficiente. Uma avaliação de "1 estrela" pode referir-se a uma lentidão no login, um erro no Pix ou uma taxa indevida — problemas distintos que exigem ações de equipes diferentes.

A literatura atual de Análise de Sentimentos em finanças frequentemente se limita à classificação de polaridade (positivo, negativo ou neutro) (Liu, 2012; Gupta et al., 2020). Existe, portanto, uma lacuna tecnológica e metodológica: a ausência de sistemas

automatizados que realizem a correlação funcional, ou seja, que vinculem a insatisfação do usuário a uma funcionalidade específica do negócio e à versão do aplicativo instalada.

O presente trabalho propõe preencher essa lacuna através do desenvolvimento de uma API (Application Programming Interface) de correlação funcional. Utilizando técnicas avançadas de Processamento de Linguagem Natural (PLN) e uma abordagem híbrida de Inteligência Artificial, a solução visa transformar o feedback textual em um backlog priorizado. O foco recai sobre a validação em tempo real, analisando dados recentes para permitir que equipes de desenvolvimento atuem proativamente na correção de bugs e na melhoria contínua dos aplicativos bancários.

Material e Métodos

A presente pesquisa classifica-se como aplicada e quantitativa, visando o desenvolvimento de um protótipo funcional para otimização de backlogs em produtos bancários. A abordagem técnica foi estruturada em quatro etapas sequenciais: coleta de dados, pré-processamento, modelagem híbrida e validação dos resultados.

Coleta e Definição do Dataset

A base de dados será constituída por avaliações públicas extraídas da Google Play Store, referentes aos aplicativos dos bancos Santander e Bradesco. A extração será automatizada via script em linguagem Python, utilizando a biblioteca google-play-scraper.

Para assegurar a relevância contemporânea dos dados e validar a eficácia da ferramenta em cenários de atualização constante (deploy contínuo), o período de coleta abrangerá uma janela recente de 90 dias. Serão capturados os seguintes atributos: conteúdo textual, classificação original (nota de 1 a 5), data e versão. A nota atribuída pelo usuário será utilizada exclusivamente para o cálculo de severidade no algoritmo de priorização de backlog, não sendo empregada como label de validação da polaridade, visto que a validação do modelo se dará por comparação com classificação humana especializada (detalhada na seção Validação e Ground Truth).

Estima-se uma amostra inicial de aproximadamente 5.000 avaliações. Este volume passará por uma etapa de higienização para exclusão de comentários vazios ou com menos de três palavras, garantindo que apenas registros com densidade semântica suficiente sejam submetidos à análise.

Seleção de Modelo e Estudo Comparativo

A definição da arquitetura Transformer baseou-se em um estudo comparativo empírico entre dois modelos pré-treinados:

- DistilBERT Multilíngue: Uma versão destilada e mais leve do BERT, focada em eficiência.
- BERTweet (XLM-RoBERTa): Um modelo robusto treinado especificamente em 198 milhões de tweets, otimizado para linguagem informal e short-text.

Os testes preliminares demonstraram que o XLM-RoBERTa apresentou superioridade estatística na detecção de sentimentos em comentários bancários, lidando melhor com ironias e jargões do setor (ex: "app rodando liso" como positivo, ou "o app só engasga" como negativo). Essa performance superior justificou sua adoção para o pipeline de produção.

Validação via Dupla Anotação Humana (Inter-Annotator Agreement)

Para garantir a confiabilidade dos resultados, não se utilizou a nota do usuário como verdade absoluta. Em vez disso, construiu-se um dataset de referência (Ground Truth) submetido a um processo de dupla anotação cega. Dois avaliadores humanos classificaram independentemente uma amostra aleatória das avaliações.

A consistência dessa anotação manual foi mensurada através do coeficiente Kappa de Cohen, métrica estatística que avalia a concordância inter-anotadores descontando-se o acaso. Somente após a resolução das discrepâncias e a validação de um índice Kappa satisfatório (> 0.60), o dataset resultante foi utilizado para aferir a acurácia, precisão e recall dos modelos de Inteligência Artificial.

Pré-processamento e Justificativa de Técnicas

Diferentemente das abordagens clássicas de Mineração de Texto que removem massivamente stop words (preposições, artigos), este projeto optou pela preservação da estrutura sintática original. Essa decisão justifica-se pela escolha de modelos baseados em arquitetura Transformer (detalhados na seção Arquitetura Híbrida de Modelagem), que utilizam mecanismos de atenção para interpretar o contexto. Como apontam Devlin et al. (2019), a remoção excessiva de palavras em modelos profundos pode ocasionar perda de nuances de sentimento, especialmente em negações (ex: "não gostei" viraria "gostei" se "não" fosse removido). O pré-processamento limitar-se-á, portanto, à limpeza de caracteres não textuais (emojis que não expressam sentimento claro) e anonimização de dados pessoais (PII), conforme diretrizes da LGPD.

Arquitetura Híbrida de Modelagem

Para balancear custo computacional e precisão semântica, desenvolveu-se uma arquitetura em dois estágios:

Estágio 1: Análise de Sentimentos (Polaridade): Utiliza-se o modelo XLM-RoBERTa (cardiffnlp/twitter-xlm-roberta-base-sentiment). A escolha deste modelo em detrimento de algoritmos mais simples (como Naive Bayes) deve-se à sua capacidade multilíngue e treinamento prévio em redes sociais, o que o torna mais robusto para lidar com a linguagem informal e gírias comuns em reviews de apps brasileiros (Liu, 2012).

Estágio 2: Correlação Funcional (Categorização): As avaliações classificadas como negativas são submetidas à API do modelo GPT-4o (OpenAI). Utiliza-se a técnica de Few-Shot Learning, onde o modelo recebe exemplos de categorização (ex: "Erro no Pix" -> Categoria "PIX") para classificar a qual funcionalidade bancária a crítica se refere. Essa abordagem supera modelos de Topic Modeling tradicionais (como LDA) ao entender ambiguidades semânticas complexas sem necessidade de treinamento supervisionado extenso.

Métricas e Validação do Modelo

A validação seguirá as recomendações estatísticas de Fávero e Belfiore (2024) para modelos de classificação. Será separado um subconjunto de controle (amostra de teste) rotulado manualmente por especialistas humanos (Gold Standard). O desempenho será mensurado através das métricas:

- **Acurácia:** Percentual global de acertos.
- **Precisão e Recall:** Para avaliar a capacidade do modelo em recuperar corretamente categorias específicas sem gerar falsos positivos.
- **F1-Score:** Média harmônica entre precisão e recall, essencial para validar o equilíbrio do modelo em categorias desbalanceadas (ex: muitas reclamações de "Login" e poucas de "Investimentos").

Integração no Fluxo Produtivo (API)

A entrega final consiste em uma API desenvolvida em Python que processa as avaliações periodicamente e disponibiliza os resultados em formato estruturado (JSON/CSV). No fluxo produtivo da equipe de desenvolvimento, esta API alimentará

um painel de Business Intelligence (ou ferramenta de gestão como o Jira/Knooly), permitindo que o Product Owner visualize um "Backlog Inteligente". Desta forma, a priorização de correções deixa de ser baseada apenas na intuição e passa a ser guiada pelo volume e criticidade das reclamações funcionais reais.

Resultados Preliminares

O título da seção Resultados Preliminares deve ser alinhado à esquerda, grafado em negrito com as primeiras letras das palavras em letras maiúsculas. É permitido que a seção seja dividida em subtópicos, seguindo a de acordo com a descrição feita no item 16.5 Resultados e Discussão e apresentados na mesma ordem da seção Material e Métodos. Nesta seção devem ser apresentados os resultados parciais obtidos na pesquisa, ou seja, os resultados obtidos até o momento.

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.

Conclusão(ões) ou Considerações Finais

Tópico obrigatório para o depósito do TCC, porém opcional para a etapa dos Resultados preliminares.

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.

Agradecimento (opcional, 1 parágrafo, bem sucinto)

O título da seção Agradecimentos deve ser alinhado à esquerda e grafado em negrito, com a primeira letra da palavra grafada em letra maiúscula. Trata-se de uma seção opcional, de no máximo três linhas, na qual o autor agradece àqueles que contribuíram de maneira relevante para o desenvolvimento do trabalho e elaboração do TCC, mas que não tiveram o envolvimento intelectual necessário à atribuição de coautoria. O autor deve se abster da menção ou citação dos nomes das empresas, instituições ou pessoas que permitiram ou contribuíram com o desenvolvimento do trabalho, a menos que esteja documentalmente autorizado a fazê-lo.

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.

Referências

ANOUBE, A. L.; ALAMRO, A. S.; AWWAD, A. A. The effect of complaint handling on customer satisfaction and loyalty in the banking sector. *International Journal of Bank Marketing*, v. 37, n. 4, p. 893-912, 2019.

DEVLIN, J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *NAACL-HLT 2019*. Minneapolis: Association for Computational Linguistics, 2019. p. 4171-4186.

FÁVERO, L. P.; BELFIORE, P. *Manual de Análise de Dados: Estatística e Machine Learning com Excel®, SPSS®, Stata®, R® e Python®*. 2. ed. Rio de Janeiro: GEN LTC, 2024.

FEBRABAN. *Pesquisa FEBRABAN de Tecnologia Bancária 2024*. São Paulo: Federação Brasileira de Bancos, 2024. Disponível em: <https://febrabantech.febraban.org.br>. Acesso em: 17 dez. 2025.

GUPTA, A. et al. Comprehensive review of text-mining applications in finance. *Financial Innovation*, v. 6, n. 37, p. 1-25, 2020.

LIU, B. *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers, 2012.

Apêndice ou Anexo (opcional)

Apêndices são textos e/ou documentos que foram elaborados pelo autor e que são importantes para complementar a argumentação do trabalho. Anexos são textos ou documentos que ilustram, mas que não foram elaborados pelos autores. Apêndices deverão seguir as mesmas normas de formatação do restante do texto, inclusive para figuras e tabelas. O TCC deverá conter no máximo 30 páginas, incluindo o(s) Apêndice(s) e/ou Anexo(s).

Atenção: antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.