

Aluno(a): Simone Rossetti Nobre Naxara

Orientador(a): Dra. Anna Carolina Martins

Curso: MBA em Data Science e Analytics

Correlação Funcional de Sentimentos em Apps Bancários: API para Priorização de Backlog

Introdução

A digitalização intensa dos serviços financeiros transformou os aplicativos móveis em canais cruciais de interação e serviço ao cliente. No Brasil, o mobile banking consolidou-se como o principal ponto de relacionamento financeiro, sendo responsável por mais de 75% das transações bancárias (FEBRABAN, 2025). Nesse cenário de alta dependência digital, as avaliações e comentários deixados pelos usuários nas lojas de aplicativos (Play Store e Apple Store) constituem um volume significativo de dados não estruturados (Big Data textual).

A gestão eficaz dessas informações é vital para a satisfação e fidelização do cliente no setor bancário (Maldonado & Freitas, 2004). A literatura sobre gestão de reclamações demonstra que a capacidade da instituição de identificar e solucionar problemas de forma eficiente está diretamente ligada ao aumento da satisfação do cliente (Anouze et al., 2019). A análise de feedback, como a realizada pelo Banco Central do Brasil (BCB), é crucial para a melhoria contínua e para evitar a insatisfação e a perda de clientes.

O uso de técnicas de Data Science é fundamental para extrair informações relevantes a partir desse Big Data textual. Para manter a experiência do cliente em um nível elevado, as instituições financeiras (como Bradesco e Santander) precisam identificar, classificar e priorizar rapidamente as reclamações e sugestões dos usuários.

A Análise de Sentimentos (Sentiment Analysis), uma subárea do Processamento de Linguagem Natural (PLN), é a técnica essencial para esse fim, pois permite classificar a polaridade emocional do texto (positivo, negativo ou neutro) (Liu, 2012). A aplicação de Text Mining em textos financeiros e bancários tem se mostrado uma ferramenta poderosa para a análise de mercado e a tomada de decisão estratégica (Gupta, 2020).

Embora a importância da análise de sentimentos em aplicativos bancários seja reconhecida, a maioria dos trabalhos existentes se concentra na classificação geral do sentimento ou na identificação de tópicos amplos. A lacuna que esta pesquisa visa preencher reside na ausência de um sistema automatizado que realize a correlação funcional do sentimento, ou seja, que ligue o sentimento negativo a uma funcionalidade específica do negócio (e.g., PIX, Login, Pagamentos) de forma precisa e acionável.

A relevância desta pesquisa reside na necessidade de transformar o feedback textual dos usuários em ações estratégicas concretas. O desafio principal consiste em correlacionar o sentimento expresso nos comentários com as funcionalidades específicas dos aplicativos bancários. A automatização desse processo por meio de uma Application Programming Interface (API), desenvolvida em Python, permitirá que as equipes de desenvolvimento utilizem um backlog gerado diretamente pela voz do cliente para subsidiar decisões críticas, como a priorização de backlog e a gestão de deploy, garantindo a consistência e validade dos dados (Malhotra et al., 2017).

O objetivo deste trabalho é desenvolver e validar um método analítico eficaz, utilizando bibliotecas Python e técnicas de PLN e classificação automática, para realizar essa classificação e correlação.

Objetivo

O objetivo principal deste projeto é desenvolver e validar uma API de correlação utilizando Processamento de Linguagem Natural e Text Mining para classificar automaticamente o sentimento dos usuários e mapear suas reclamações para funcionalidades de negócio em avaliações de aplicativos bancários (Bradesco e Santander), fornecendo um sistema de apoio à decisão para a priorização de backlog e gestão de deploy.

Objetivos Específicos:

1. Coletar e estruturar um dataset unificado de avaliações dos aplicativos (Play Store e Apple Store).
2. Implementar técnicas de Análise de Sentimentos utilizando PLN para classificar os reviews (positivo, negativo, neutro).
3. Aplicar técnicas de Text Mining e Clustering para categorizar as reclamações em funcionalidades de negócio (e.g., Login e Acesso, PIX, Lentidão, Empréstimos).
4. Construir a API de correlação em Python que integre sentimento, funcionalidade e volume de ocorrências, gerando um backlog priorizado para subsidiar a tomada de decisão sobre deploy.
5. Avaliar a eficácia (acurácia) da solução desenvolvida, validando o modelo de classificação automática para a tarefa de correlação.

Metodologia: Implementação de Algoritmo(s) de Classificação

Comentado [ACM1]: •A metodologia está adequada para a natureza aplicada, mas a descrição dos algoritmos de classificação e técnicas de pré-processamento deve ser mais detalhada, incluindo justificativas para escolha dessas técnicas específicas.
•O processo de validação do modelo pode ser ampliado para incluir métricas complementares (ex. F score, recall) e uma descrição clara do dataset (quantidade de amostras, critérios de seleção).
•Ainda, deve-se explicitar como será feita a integração da API no fluxo produtivo das equipes de desenvolvimento.

O delineamento metodológico escolhido é a Implementação de Algoritmo(s) de Classificação, que é um método recomendado para o curso de Data Science e Analytics. O projeto terá natureza aplicada e utilizará Levantamento de Dados Secundários como técnica de obtenção de dados (Prodanov & Freitas, 2013).

a) Fontes e Coleta de Dados

A pesquisa será realizada a partir de dados secundários, consistindo nas avaliações e comentários de usuários dos aplicativos dos bancos Bradesco e Santander, disponíveis publicamente nas lojas de aplicativos (Play Store e Apple Store). Por se tratar de dados públicos, a pesquisa utilizará informações de acesso público. Contudo, será observada a necessidade de preenchimento do Formulário de Direcionamento Ético [FDE], garantindo a anonimização e a não divulgação do nome da instituição ou de seus clientes (Gil, 2017).

b) Text Mining e Pré-processamento

O processo analítico se inicia com o Text Mining (Mineração de dados textuais), que é fundamental para obter informações importantes a partir do texto. O Text Mining envolve a extração de informações de alta qualidade a partir de texto não estruturado, por meio da aplicação de técnicas de Processamento de Linguagem Natural (PLN) e algoritmos de classificação, transformando o texto em dados estruturados que podem ser analisados (Feldman & Sanger, 2007; Agarwal & Mittal, 2016).

Para garantir a qualidade do modelo, o processo de pré-processamento será detalhado, incluindo:

1. Limpeza e Normalização: Remoção de caracteres especiais, pontuações e emojis.
2. Tokenização e Lematização: Divisão do texto em unidades (tokens) e redução das palavras à sua forma canônica.
3. Remoção de Stop Words: Exclusão de palavras de alta frequência e baixo valor semântico.
4. Feature Engineering: Transformação do texto em representações numéricas (vetores) utilizando técnicas como TF-IDF (Term Frequency-Inverse Document Frequency) ou Word Embeddings (como Word2Vec ou FastText), permitindo que os algoritmos de classificação possam processá-los.

c) Implementação do Algoritmo

O foco do TCC é o desenvolvimento e validação da API de correlação. Esta correlação será realizada por meio de técnicas de Classificação Automática de Textos. Serão utilizadas Técnicas de Classificação Supervisionadas (como a Regressão Logística, conforme sugerido por Kadhim (2019)) para a classificação automática dos textos na solução desenvolvida em Python.

A escolha do algoritmo será justificada pela sua eficácia em tarefas de classificação de texto e pela sua interpretabilidade. O processo de validação do modelo será ampliado para incluir métricas complementares, além da acurácia, como:

- **Precisão (Precision):** Mede a proporção de identificações positivas que foram realmente corretas.
- **Revocação (Recall):** Mede a proporção de positivos reais que foram identificados corretamente.
- **F1-Score:** Média harmônica entre Precisão e Revocação, oferecendo uma métrica única de desempenho.

O dataset será caracterizado por:

- **Quantidade de Amostras:** Serão utilizados os comentários de aplicativos bancários (Bradesco e Santander) disponíveis publicamente, com o objetivo de obter um volume significativo de dados (ex: mais de 10.000 comentários).
- **Critérios de Seleção:** Os dados serão selecionados com foco em comentários que contenham texto e classificação de estrelas, para facilitar a rotulagem inicial (supervisionada).

d) Fluxo de Integração da API

A API de correlação será desenvolvida em Python (utilizando frameworks como Flask ou FastAPI) e será projetada para se integrar ao fluxo produtivo das equipes de desenvolvimento. O fluxo de integração será o seguinte:

1. **Entrada de Dados:** A API receberá novos comentários de aplicativos (Play Store/App Store) via webhook ou chamada programada.
2. **Processamento:** O modelo de classificação treinado será executado para:
 - Classificar o Sentimento (Positivo, Negativo, Neutro).
 - Classificar a Funcionalidade (PIX, Login, etc.).
3. **Saída e Ação:** A API retornará um resultado estruturado (JSON) contendo o Sentimento, a Funcionalidade e o Volume de Ocorrências. Este resultado será consumido por ferramentas de gestão de projetos (backlog) como o Jira ou AzureDevOps, permitindo que a equipe:
 - **Priorize Backlog:** Crie automaticamente tickets para funcionalidades com alto volume de sentimentos negativos.
 - **Gestão de Deploy:** Correlacione a ocorrência de sentimentos negativos com a versão do aplicativo, permitindo a identificação imediata de problemas introduzidos por um deploy recente.

Resultados Esperados

Espera-se, ao final da pesquisa, ter desenvolvido e implementado um modelo de classificação automática de textos em uma API funcional, utilizando bibliotecas Python. O resultado principal será a validação da eficácia (medida por acurácia e outras métricas relevantes) do modelo proposto na tarefa de correlacionar sentimentos de usuários com funcionalidades específicas dos aplicativos, oferecendo visibilidade sobre os pontos fortes e fracos da experiência do usuário.

Os resultados permitirão a geração automatizada de um backlog priorizado. Esse backlog discriminará as funcionalidades dos aplicativos que concentram maior volume de sentimentos negativos, possibilitando que as equipes de desenvolvimento atuem de forma mais proativa na gestão de deploy e na evolução dos produtos, correlacionando o feedback do usuário com a versão e a funcionalidade do aplicativo.

Cronograma de Atividades

O cronograma abaixo planeja a execução da pesquisa e a redação do TCC, considerando as etapas de entrega do curso.

Atividades planejadas	Mês									
	09	10	11	12	01	02	03	04	05	06
Revisão da literatura e fundamentação teórica (Text Mining, Análise de Sentimento, Modelos de Classificação)	X									
Elaboração e envio do Formulário de Direcionamento Ético [FDE] e Projeto de Pesquisa.	X	X								
Definição detalhada da Metodologia e preparação dos dados (Pré-processamento e Feature Engineering)		X								
Implementação da solução em Python (Modelo de Classificação Supervisionado)			X	X						
Validação da eficácia (acurácia) do modelo de classificação.					X					
Redação dos Resultados Esperados e Discussão						X				
Redação e revisão final do TCC							X	X		
Entrega Final do TCC									X	

Referências

Agarwal, B.; Mittal, N. 2016. Text mining: a survey on techniques and applications. World Scientific News 42: 100-119.

Anouze, A.L.; Alamro, A.S.; Awwad, A.A. 2019. The effect of complaint handling on customer satisfaction and loyalty in the banking sector. International Journal of Bank Marketing 37(4): 893-912.

Banco Central do Brasil [BCB]. 2025. Ranking de Reclamações. Disponível em: <https://www.bcb.gov.br/meubc/rankingreclamacoes>. Acesso em: 27 out. 2025.

Federação Brasileira de Bancos [FEBRABAN]. 2025. Mobile banking é responsável por 75% das transações bancárias no Brasil. Disponível em: <https://febrabantech.febraban.org.br/temas/inovacao/mobile-banking-e-responsavel-por-75-das-transacoes-bancarias-no-brasil>. Acesso em: 26 out. 2025.

Feldman, R.; Sanger, J. 2007. The Text Mining Handbook: Advanced Approaches in Analyzing Unstructured Data. Cambridge University Press, New York, NY, USA.

Gil, A.C. 2017. Como Elaborar Projetos de Pesquisa. 6ed. Atlas, São Paulo, SP, Brasil.

Gupta, A.; Dengre, V.; Kheruwala, H.A.; Shah, M. 2020. Comprehensive review of text-mining applications in finance. Financial Innovation 6(37): 1-25.

Kadhim, A.I. 2019. Survey on supervised machine learning techniques for automatic text classification. Artificial Intelligence Review 52(1): 273-292.

Liu, B. 2012. Sentiment Analysis and Opinion Mining. Morgan & Claypool Publishers, CA, USA.

Malhotra, N.K.; Nunan, D.; Birks, D.F. 2017. Pesquisa de Marketing: Uma Orientação Aplicada. 7ed. Pearson Education do Brasil, São Paulo, SP, Brasil.

Prodanov, C.C.; Freitas, E.C. 2013. Metodologia do Trabalho Científico: Métodos e técnicas da pesquisa e do trabalho acadêmico. 2ed. Feevale, Novo Hamburgo, RS, Brasil.