

K-Means Clustering e Regressão Logística: identificação de potenciais clientes para solução tecnológica de dados

Maiza Garcia Belini Antunes ^{1*}; Guilherme André Peleglini Rocha ²

¹ Capgemini Portugal. Analista de Testes. Rua Senhora da Luz, 15 - Marinha da Guia; 3105-063 Pombal, Leiria, Portugal

² Escola Superior de Agricultura “Luiz de Queiroz”, Universidade de São Paulo. Mestre em Economia. Avenida Pádua Dias, 11 – São Dimas; 13418-900 Piracicaba, São Paulo, Brasil

*autor correspondente: maizabelini075@gmail.com

K-Means Clustering e Regressão Logística: identificação de potenciais clientes para solução tecnológica de dados

Resumo

Micro, pequenas e médias empresas frequentemente enfrentaram uma série de desafios para adotar soluções tecnológicas, desafios esses que podem estar relacionados à limitação de recursos financeiros, resistência cultural à inovação e falta de conhecimento técnico. Muitos empreendedores têm dificuldade em perceber os benefícios e o valor de investir na transformação digital, especialmente quando não há uma compreensão clara sobre como essas tecnologias podem impulsionar o crescimento e garantir a sustentabilidade do negócio. Diante desse cenário, o presente trabalho tem como objetivo analisar o perfil dos empreendedores e as características das empresas por meio do método de clusterização, com o intuito de identificar e segmentar um público-alvo. Ao compreender esses perfis, buscou-se identificar as empresas com maior propensão à adoção de soluções tecnológicas e, assim, apoiar empresas fornecedoras dessas soluções em suas abordagens de venda e na implementação de estratégias personalizadas. Com base no “dataset estudado” pode-se dizer que a análise exploratória revelou que a maioria dos respondentes era do gênero feminino (58,5%), com ensino médio completo (52,5%), e que as empresas eram microempresas (87,9%), com até quatro funcionários, com menos de cinco anos de existência (69,8%) e sem parcerias institucionais (82,9%). A clusterização permitiu identificar seis perfis distintos entre os empreendedores. A regressão logística apontou maior propensão à adoção entre jovens com até 30 anos, proprietários do negócio e com parcerias com universidades ou indústrias. O modelo preditivo apresentou bons resultados, com acurácia de 69%, sensibilidade de 89%, F1-score de 80% e AUC de 0,69.

Palavras-chave: Transformação Digital; PME's; Digitalização; Desafios; Soluções tecnológicas.

K-Means Clustering and Logistic Regression: Identifying Potential Clients for Data Technology Solutions

Abstract

Micro, small, and medium-sized enterprises often faced a series of challenges in adopting technological solutions, which could be related to limited financial resources, cultural resistance to innovation, and lack of technical knowledge. Many entrepreneurs had difficulty perceiving the benefits and the value of investing in digital transformation, especially when there was no clear understanding of how these technologies could drive growth and ensure business sustainability. In this context, the present study aimed to analyze the profile of entrepreneurs and the characteristics of their companies through the clustering method, in order to identify and segment a target audience. By understanding these profiles, the goal was to identify the companies most likely to adopt technological solutions and thus support technology providers in their sales approaches and implementation of personalized strategies. The exploratory analysis revealed that most respondents were female (58.5%), with a high school education (52.5%), and that the companies were micro-enterprises (87.9%) with up to four employees, less than five years in operation (69.8%), and no institutional partnerships (82.9%). Clustering made it possible to identify six distinct profiles among the entrepreneurs. Logistic regression indicated a higher likelihood of adoption among young entrepreneurs aged 30 or below, business owners, and those with partnerships with universities or industries. The predictive model showed good performance, with 69% accuracy, 89% sensitivity, an F1-score of 80%, and an AUC of 0.69.

Keywords: Digital Transformation; SMEs; Digitalization; Challenges; Technological Solutions.

Introdução

No cenário atual, a quantidade de dados gerados cresce de forma exponencial, resultando em uma enorme quantidade de informações brutas que precisam ser processadas e analisadas para se tornarem úteis. Compreender e transformar esses dados em informações relevantes é uma tarefa imprescindível para empresas que buscam se manter competitivas no mercado. A coleta, transformação e análise de dados são processos fundamentais para o desenvolvimento de estratégias de mercado mais eficazes, melhor posicionamento e aumento da base de clientes e das vendas, portanto, a análise eficiente dos dados permite às empresas compreenderem melhor o comportamento de seus consumidores, otimizar suas operações e identificarem novas oportunidades de negócios (Oliveira et al., 2023).

Enquanto grandes corporações têm recursos para investir em infraestrutura e especialistas, pequenas e médias empresas [PMEs] enfrentam desafios significativos na adoção de soluções tecnológicas, especialmente de análise de dados. Oliveira et al. (2023) menciona que além de limitações financeiras, tecnológicas e humanas, muitos empreendedores desconhecem o valor da transformação digital e da tomada de decisões orientada a dados, criando muita das vezes barreiras que limitam muitos empreendedores de conhecerem melhor seus próprios comércios.

Superar essas barreiras exige investimento, e isso é um fato, mas o maior obstáculo talvez seja a falta de conhecimento e conscientização, a desconfiança em soluções digitais, o medo de enfrentar desafios de segurança digital e a ausência de uma cultura enraizada que valorize o uso e necessidade de dados estratégicos para orientação do negócio (Bianchini e Michalkova, 2019).

Em um contexto, que demanda práticas sustentáveis, inovação e capacidade de gerar retornos financeiros rapidamente (Carneiro, 2017) grandes empresas se posicionam na vanguarda da transformação digital, utilizando dados para prever tendências, personalizar o atendimento ao cliente, otimizar operações e promover a sustentabilidade em suas empresas. Em contraste, muitas PMEs ainda enxergam a análise de dados como algo complexo, caro e distante de sua realidade, criando uma lacuna significativa no mercado, ficando em desvantagem competitiva, pois não conseguem acompanhar as rápidas mudanças do mercado e adaptar suas estratégias com a mesma agilidade de grandes corporações.

No entanto, a falta de entendimento a nível gerencial ou inflexibilidade sobre a necessidade de mudança de práticas comerciais tradicionais que “funcionaram bem no passado” (Bianchini e Michalkova, 2019) perpetuam múltiplos processos morosos e manuais, que geram o excesso de trabalho – e que poderiam ser otimizados e concederem lugar para

atividades que requerem do pensamento crítico e analítico do ser humano. Esse modelo de gerenciamento frequentemente se baseia na intuição ou em dados fragmentados e desatualizados, o que pode levar a tomada de decisões ineficazes, desperdício de recursos e oportunidades perdidas.

Outros fatores que podem influenciar a decisão de utilização ou não da análise de dados em pequenas e médias empresas incluem o tempo de atuação (como empresas familiares ou empreendimentos sociais e empresariais), o nível de mercado atendido (internacional, nacional, regional ou local), e a escassez de recursos humanos qualificados (Carneiro, 2017). Embora existam ferramentas de análise de dados que variam desde opções gratuitas até as mais sofisticadas que combinam estatísticas, matemática e ciência da computação, a falta de profissionais capacitados impede que as PMEs se beneficiem. Como consequência, a implementação de soluções baseadas em dados torna-se um processo complexo e oneroso para essas empresas, que acabam sem acesso ao suporte necessário para interpretar e aplicar os resultados das análises (Klein e Todesco, 2020).

Diante desse contexto e com base nos dados apresentados na Comissão Europeia (European Commission, 2013) torna-se necessário investigar maneiras de auxiliar as PMEs a superar esses desafios e a compreender melhor as vantagens da transformação digital. Incentivos governamentais, políticas de suporte e programas de formação voltados para o uso de tecnologia em pequenas empresas podem reduzir barreiras, oferecendo acesso a recursos e capacitação. Esse apoio não apenas facilita a integração das PMEs na era digital, mas também gera impactos positivos para o desenvolvimento econômico do país. Ao fortalecer a competitividade e sustentabilidade das PMEs, o governo promove a geração de empregos, aumenta a arrecadação de impostos e impulsiona a inovação local.

Portanto, o presente trabalho tem como objetivo investigar o potencial de micros, pequenos e médios empreendedores para adoção de novas tecnologias. Com o uso de técnicas de “Machine Learning”, como Clusterização e Regressão Logística, pretende-se identificar segmentos de PMEs que possuam maior propensão para adotar soluções tecnológicas, levando em conta características como familiaridade com tecnologia e tempo de mercado. O objetivo final é oferecer “insights” que permitam à uma “start-up” de solução de dados desenvolver estratégias de segmentação de mercado mais precisas, apoiando o crescimento digital das PMEs e fortalecendo sua competitividade no cenário econômico atual.

Material e Métodos

Neste capítulo descreve-se os dados utilizados para a realização da pesquisa, assim como as ferramentas e métodos empregados em todas as etapas do trabalho. As sessões

estão divididas em: apresentação dos dados, breve descrição dos modelos avaliados, Clusterização e Regressão logística, e definição das métricas de desempenho usadas na interpretação dos resultados.

Apresentação dos dados

Para a execução deste trabalho, utilizou-se a base de dados “SMEs Survey of Digital Adoption”, disponível na plataforma “Kaggle”¹. Essa base dispõe de 381 respostas de um questionário composto por 38 perguntas, realizado na Indonésia, cujo objetivo foi captar características e comportamentos de responsáveis ou proprietários de “PMEs” para diferentes temas (Empreendedorismo, Competência Empresarial, Estratégia de Resiliência Sustentável e Adoção de Tecnologia Digital) e seus níveis de relevância para cada organização.

Tabela 1. Dataset Original

Categoria	Variável	Descrição
Características do Respondente	Gênero	Gênero do respondente.
	Idade	Idade do respondente.
	Escolaridade	Nível de escolaridade do respondente.
	Cargo	Cargo ou posição ocupada no negócio.
	TempoTrabalho	Tempo de trabalho no negócio.
	Cidade	Cidade onde o negócio está localizado.
	SetorNegócio	Setor de atuação principal do negócio.
Características do Negócio (SME)	ForçaTrabalho	Quantidade de colaboradores atualmente ativos.
	IdadeMSME	Tempo de existência da Micro, Pequena ou Média Empresa (PME).
	ParceriaDupla	Participa de parceria com mais uma entidade (Parceria Dupla - DP).
	ParceriaTripla	Participa de parceria com duas ou mais entidades (Parceria Tripla - TP).
	AU	Autonomia: Nosso negócio tem independência para transformar ideias em realidade.
Empreendedorismo	INN	Inovação: Periodicamente, nosso negócio sempre lança novos produtos.
	RT	Tomada de Risco: Nosso negócio ousa tomar decisões de alto risco.
	PA	Proatividade: Em todas as situações, nosso negócio sempre toma a iniciativa em vez de "esperar silenciosamente".
	CA	Agressividade Competitiva: Nosso negócio aproveita agressivamente oportunidades de mercado ou outras potenciais oportunidades.
	OEO	Orientação Empreendedora Geral: No geral, nosso negócio tem uma boa orientação empreendedora.
Competência Empresarial	OPC	Competência em Oportunidade: Nosso negócio está constantemente buscando oportunidades de desenvolvimento por meio de atividades promocionais e de marketing.

¹ Disponível em: <https://www.kaggle.com/datasets/ivandirvana/smes-survey-of-digital-adoption>

Tabela 1. Dataset Original

		(conclusão)
Categoria	Variável	Descrição
Estratégia de Resiliência Sustentável	RC	Competência em Relacionamento: Nosso negócio está constantemente construindo/mantendo relacionamentos com clientes existentes e potenciais, parceiros ou associações empresariais.
	CCC	Competência Criativa e Crítica: A busca por uma solução para um problema empresarial sempre considera uma variedade de diferentes pontos de vista.
	ORC	Competência Organizacional: A preparação de planos, alocação de recursos e supervisão nos negócios são sempre bem realizadas.
	STC	Competência Estratégica: O estabelecimento de metas empresariais é feito de forma formal e flexível para alcançá-las realisticamente.
	CMC	Competência em Comprometimento: Desde a sua criação, durante tempos de crise, mesmo em condições de intensa concorrência, o compromisso com o negócio permaneceu firme.
	OEC	Competência Empreendedora Geral: No geral, nosso negócio tem uma boa competência empreendedora.
	SU	Adaptabilidade: Quando ocorre uma crise, nosso negócio tem a capacidade de se adaptar às circunstâncias para resolver problemas de maneira criativa.
	SY	Acesso a Recursos: Nosso negócio tem fácil acesso aos recursos necessários para lidar com restrições/limitações durante uma crise.
	CO	Conectividade Digital: Nosso negócio utiliza tecnologia digital para se manter conectado às mudanças do mercado, além de acessar recursos para garantir a continuidade dos negócios.
	REO	Reorientação Estratégica: Nosso negócio realizou várias reorientações relacionadas a insumos, processos e produtos para se alinhar às demandas dos Objetivos de Desenvolvimento Sustentável (ODS).
	OSRS	Resiliência Geral: No geral, nosso negócio possui resiliência sustentável para micro, pequenas e médias empresas (PMEs).
	IA	Acesso à Internet: Disponibilidade de acesso à internet/rede no ambiente de trabalho.
	II	Dispositivos Conectados: Disponibilidade de dispositivos móveis/computadores conectados à internet no ambiente de trabalho.
	IT_SM	Vendas e Marketing Digital: Uso de tecnologia digital para vendas e marketing empresarial.
	IT_CS	Atendimento ao Cliente Digital: Serviço ao cliente utilizando tecnologia digital.
Adoção de Tecnologia Digital	IT_PD	Inovação e Desenvolvimento de Produtos: Busca por inovação e ideias para desenvolvimento de produtos utilizando tecnologia digital.
	IT_DM	Tomada de Decisão Digital: A tecnologia digital acelera a tomada de decisões nos negócios de forma precisa.
	IT_KM	Gestão do Conhecimento: A gestão do conhecimento no ambiente de trabalho, relacionada a negócios e oportunidades, torna-se mais eficaz e eficiente com o uso da tecnologia digital.
	IT_SCM	Gestão da Cadeia de Suprimentos: Processos de gestão da cadeia de suprimentos utilizando tecnologia digital.
	ODTA	Adoção Geral de Tecnologia Digital: De forma geral, nosso negócio adota tecnologia digital em suas operações.

Fonte: Dados originais da pesquisa

Para realizar o estudo proposto, selecionou-se as variáveis relacionadas às características dos respondentes e das empresas, além da variável ODTA, uma vez que o objetivo do estudo foi identificar perfis de empreendedores e, em seguida, analisar a probabilidade de adoção de novas soluções tecnológicas. As informações sociodemográficas e organizacionais permitem agrupar empreendedores com características semelhantes, enquanto a variável ODTA serve como indicador do nível de adoção tecnológica, possibilitando avaliar quais perfis estão mais propensos à digitalização dos seus negócios.

Com o intuito inicial de compreender melhor as informações presentes na base de dados, aplicou-se Análise Exploratória de Dados [EDA], um conjunto de técnicas estatísticas e visuais que permitiram identificar estrutura, padrões e qualidade dos dados. Para as variáveis numéricas, utilizou-se das medidas de tendência central (média e mediana) e de dispersão (desvio padrão, valores mínimo e máximo, quartis e intervalo interquartil), enquanto no caso das variáveis categóricas, foram analisadas as frequências absolutas e relativas. Adicionalmente, foram utilizadas visualizações gráficas que facilitaram a identificação de padrões visuais e tendências. Essa metodologia está alinhada aos princípios propostos por Tukey (1977), que destacou a importância da análise exploratória de dados como etapa fundamental para análises estatísticas complementares.

Clusterização (K-means)

Para obtenção da classificação dos dados, utilizou-se da técnica “K-Means Clustering”, um algoritmo de aprendizado não supervisionado cujo objetivo é agrupar os respondentes com base em características semelhantes. Embora o K-Means não exija uma variável-alvo, neste estudo adotou-se a variável ODTA como referência para validação dos agrupamentos.

Das 38 variáveis contidas na base de dados, selecionaram-se 10 variáveis relacionadas a dados demográficos, parcerias e adoção de tecnologia digital. A implementação do modelo foi feita na linguagem “Python”, utilizando a biblioteca “Scikit-Learn” e a função “sklearn.cluster.KMeans”, que organiza os dados em K “clusters” com base na similaridade.

Realizou-se a normalização dos dados por meio do “Z-score”, conforme a form. (1) descrita:

$$Z = \frac{X - \mu}{\sigma} \quad (1)$$

onde, X representa o valor original da variável; μ a média da variável; σ o desvio padrão da variável.

Em seguida, criou-se uma matriz de dissimilaridade utilizando a distância euclidiana que mede o grau de diferença entre as observações do conjunto de dados. A eq. (2) é descrita abaixo:

$$d(A,B) = \sqrt{\sum_{i=1}^n (A_i - B_i)^2} \quad (2)$$

onde, A_i e B_i representam os valores das variáveis para dois respondentes distintos.

Após a normalização e definição da matriz de dissimilaridade, determinou-se o número ideal de clusters, através do “Elbow Method”, que avalia a variação da inércia do modelo para diferentes valores de K . A inércia é representada pela eq. (3):

$$WCSS \equiv \sum_{i=1}^k \sum_{x \in C_i} \|x - u_i\|^2 \quad (3)$$

onde, WCSS “Within-Cluster Sum of Squares” representa a soma dos erros quadráticos dentro de cada cluster; x são os pontos de dados pertencentes ao cluster C_i e u_i é o centróide do cluster.

Após definir k , executou-se o algoritmo K-Means, atribuindo um cluster a cada respondente com base na similaridade. A variável-alvo foi removida, mantendo-se apenas as variáveis explicativas juntamente com a coluna do cluster atribuído.

Para avaliar a capacidade do modelo de generalizar para novos dados, dividiu-se o conjunto de dados em 80% para treinamento e 20% para teste. O modelo treinado foi então aplicado para prever os clusters de novas observações, permitindo uma análise mais detalhada dos padrões existentes nos dados.

Regressão Logística

Para classificação e obtenção de informações de probabilidade de PMEs adotarem ou não soluções tecnológicas com base nas variáveis disponíveis no “dataset”, utilizou-se do método de regressão logística binária, que é um tipo de Modelo Linear Generalizado [GLM] e que segundo Fávero e Belfiore (2017), assume distribuição binomial e é especialmente utilizada para prever a ocorrência de eventos com desfechos dicotômicos.

Para calcular a probabilidade de um evento ocorrer com base em um conjunto de variáveis explicativas, definiu-se um vetor logito através da Eq. (4):

$$z_i = \alpha + \beta_1 X_{1i} + \dots + \beta_k X_{ki} \quad (4)$$

onde, z_i é o logito associado à i -ésima observação, X_{ki} são os valores das variáveis explicativas, α é o intercepto do modelo e β_k os coeficientes estimados para cada variável. A partir do logito, a probabilidade de ocorrência do evento é obtida por meio da eq. (5):

$$P_i = \frac{e^{z_i}}{1 + e^{z_i}} = \frac{1}{1 + e^{-z_i}} \quad (5)$$

em que essa função transforma o logito em uma probabilidade que varia entre 0 (não evento) e 1 (evento), tornando o modelo apropriado para análises preditivas com variáveis dependentes qualitativas binárias.

Entretanto, antes da aplicação do modelo, foi necessário realizar o tratamento das variáveis, começando pela conversão das variáveis categóricas em variáveis binárias “dummies”, utilizando o comando “get_dummies” da biblioteca Pandas. Em seguida, foi realizado um processo de seleção empírica das variáveis mais relevantes para a previsão da variável-alvo:

- A presença de multicolinearidade entre as variáveis explicativas foi verificada por meio do cálculo do Fator de Inflação da Variância [FIV], permitindo a identificação de correlações elevadas entre os preditores.
- Como segunda abordagem, aplicou-se a Eliminação Recursiva de Variáveis [RFE], utilizando a função RFE da biblioteca “sklearn”. Esse método foi empregado no modelo inicial com o objetivo de avaliar a importância de cada variável, removendo iterativamente aquelas com menor relevância, contribuindo assim para o aprimoramento da acurácia do modelo.
- Por fim, adotou-se o procedimento “stepwise”, com o apoio da função “stepwise” do pacote “stepwise_process”, que adiciona ou remove variáveis com base na significância estatística. Esse processo é repetido até que o modelo GLM final apresente variáveis com nível de significância inferior a 5%, exceto o intercepto.

A variável-alvo selecionada para este modelo é a adoção ($y = 1$) ou não adoção ($y = 0$) da tecnologia digital nas operações empresariais, representada pela variável ODTA.

Após definir a estrutura do modelo, a base de dados foi dividida em dois conjuntos: 80% dos dados foram utilizados para o treinamento do modelo e 20% para a avaliação de sua performance (teste). Essa divisão garantiu uma validação adequada e evitou o “overfitting”.

Por fim, o modelo treinado foi aplicado para prever a probabilidade de um novo respondente se enquadrar em uma das classes previstas (adoção ou não adoção), permitindo assim a análise de padrões e tendências nos dados.

Para interpretar esses resultados de forma mais intuitiva, após ajustar o modelo de regressão logística, aplicou-se a exponenciação aos coeficientes log-odds para transformá-los em razões de chances “odds ratios”. Essa etapa foi realizada porque os coeficientes da regressão logística expressam a relação entre as variáveis preditoras e o logaritmo das chances do evento ocorrer e ao aplicar a exponenciação, convertemos essa relação em uma forma mais intuitiva, a razão de chances, que mostra o quanto as chances de um evento mudarão ao variar uma variável preditora.

Métricas de desempenho

Após a execução dos modelos, utilizou-se de métricas de desempenho para avaliação dos resultados obtidos. Para o K-Means, foram utilizadas métricas como inércia, índice de silhueta e distância intra-cluster média para avaliar a qualidade da formação e separação dos clusters.

Na eq. 6, a distância intra-cluster média calcula a distância média entre todos os pontos dentro de um cluster, oferecendo uma ideia de quão compactos são os clusters formados.

$$\text{Distância média intra cluster} = \frac{1}{|C_i|} \sum_{x_j \in C_i} \|x_j - \mu_i\| \quad (6)$$

onde, $|C_i|$ é o número de pontos no cluster C_i ; μ_i é o centroide do cluster.

Na eq. 7, o índice de silhueta mede o quão bem cada ponto está classificado dentro de seu cluster, comparando a distância média intra-cluster e a distância média ao cluster mais próximo.

$$s(i) = \frac{b(i) - a(i)}{\max_{j \neq i}(a(i), b(i))} \quad (7)$$

onde, $a(i)$ é a distância média entre o ponto i e todos os outros pontos dentro do mesmo cluster; $b(i)$ é a distância média entre o ponto i e todos os pontos do cluster mais próximo.

Além das métricas, foram gerados os gráficos PCA e t-SNE, que contribuíram para a visualização e compreensão dos padrões dos dados.

Já no caso da Regressão Logística, para avaliar o desempenho do modelo e identificar possíveis melhorias nas previsões as principais métricas utilizadas para avaliar o desempenho do modelo podemos destacar:

Acurácia (eq. 8): que representa a proporção de previsões corretas feitas pelo modelo em relação ao total de observações.

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN} \quad (8)$$

onde, TP (True Positives) são os verdadeiros positivos; TN (True Negatives) são os verdadeiros negativos; FP (False Positives) são os falsos positivos; FN (False Negatives) são os falsos negativos.

Precisão (eq. 9): mede a proporção de exemplos classificados como positivos que realmente são positivos.

$$\text{Precisão} = \frac{TP}{TP+FP} \quad (9)$$

Recall (eq. 10): mede a proporção de exemplos positivos que o modelo conseguiu identificar corretamente.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (10)$$

F1-score (eq. 11): é a média harmônica entre precisão e recall, oferecendo uma métrica balanceada quando há um desbalanceamento entre classes.

$$F1 = \frac{\text{Precisão} * \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (11)$$

A matriz de confusão é uma tabela que mostra o desempenho do modelo, detalhando o número de acertos e erros nas classificações e a partir dela, pode-se observar o valor da sensibilidade e especificidade, AUC-ROC.

Resultados e discussão

Esta seção está dividida em três tópicos: análise exploratória, clusterização e regressão logística, com o objetivo de apresentar a análise final orientada pelo estudo teórico realizado.

Análise exploratória

De forma a conhecer a base de dados a ser trabalhada, primeiramente identificaram-se as variáveis presentes no conjunto de dados. A Tabela 2 apresenta as variáveis disponíveis, a quantidade total de registros por variável, a ausência de valores nulos e o tipo de dado identificado.

Tabela 2. Estrutura do Dataset: Variáveis e Tipos de Dados

ID	Variável	Contagem	Nulos	Tipo de dados
0	Gender	381	non-null	object
1	Respondent Age	381	non-null	object
2	Education	381	non-null	object
3	Position	381	non-null	object
4	Working period	381	non-null	object
5	City	381	non-null	object
6	Business fields	381	non-null	object
8	MSME age	381	non-null	object
9	Double partnership (DP)	381	non-null	object
10	Triple partnership (TP)	381	non-null	object
29	IA	381	non-null	int64
30	II	381	non-null	int64
31	IT_SM	381	non-null	int64
32	IT_CS	381	non-null	int64
33	IT_PD	381	non-null	int64
34	IT_DM	381	non-null	int64
35	IT_KM	381	non-null	int64
36	IT_SCM	381	non-null	int64
37	ODTA	381	non-null	int64

Fonte: Resultados originais da pesquisa

No passo a seguir, verificou-se a estatística descritiva das colunas numéricas da qual foi possível gerar um gráfico de distribuição para perceber as notas atribuídas para cada variável (questão) pertencente ao grupo Adoção de Tecnologia Digital.

- IA: Disponibilidade de acesso à internet/rede no ambiente de trabalho;
- II: Disponibilidade de dispositivos móveis/computadores conectados à internet no ambiente de trabalho;
- IT_SM: Uso de tecnologia digital para vendas e marketing empresarial;
- IT_CS: Serviço ao cliente utilizando tecnologia digital;
- IT_PD: Busca por inovação e ideias para desenvolvimento de produtos utilizando tecnologia digital;

- IT_DM: A tecnologia digital acelera a tomada de decisões nos negócios de forma precisa;
- IT_KM: A gestão do conhecimento no ambiente de trabalho, relacionada a negócios e oportunidades, torna-se mais eficaz e eficiente com o uso da tecnologia digital;
- IT_SCM: Processos de gestão da cadeia de suprimentos utilizando tecnologia digital;
- ODTA : De forma geral, nosso negócio adota tecnologia digital em suas operações.




Figura 1. Distribuição das variáveis numéricas
Fonte: Resultados originais da pesquisa

Foram geradas visualizações gráficas, conforme apresentado na Figura 2, que auxiliaram na análise exploratória, facilitando a identificação de padrões, outliers ou possíveis correlações entre as variáveis.




Figura 2. Distribuição das variáveis categóricas

Fonte: Resultados originais da pesquisa

Após a realização da análise exploratória dos dados, identificaram-se algumas características predominantes entre os respondentes da pesquisa:

- A maior parte do público foi composto por mulheres (58,5%).
- De forma geral, o nível de escolaridade apresentado foi o ensino médio completo (52,5%).

E sobre as PMEs:

- A maioria possuía entre 1 e 4 funcionários (87,9%), com tempo médio de existência menor que 5 anos (69,8%) e que não mantinha parceria com nenhuma instituição (82,9%), o que pode indicar uma operação mais independente.

A partir da análise exploratória dos dados já foi possível observar características de empreendedores e PMEs para uma possível definição do público-alvo. No entanto, para aumentar a assertividade, será utilizado técnicas complementares de modelagem, como clusterização e regressão logística.

Clusterização

Iniciou-se a etapa de clusterização com a seleção das variáveis, codificação dummy, a normalização dos dados e análise da matriz de dissimilaridade, a seguir, analisou-se o momento em que a redução da inércia se tornou menos significativa, através da Figura 6 que

representa graficamente o “Elbow Method” nos direcionando para $k = 6$, como o número ótimo de clusters.




Figura 6. Elbow Method

Fonte: Resultados originais da pesquisa

Essa escolha também foi reforçada pelas métricas de desempenho mencionadas abaixo, onde $k=6$ apresenta o melhor equilíbrio entre coesão interna (menor distância intra-cluster), separação entre grupos (maior índice de silhueta) e uma redução significativa da inércia.

Tabela 3. Métricas de Desempenho (K-Means)

Nº Clusters	2	4	6	8	10
Inércia (SSE)	11141,4	10097,85	8477,54	7345,92	6985,95
Índice de Silhueta	0,11	0,13	0,17	0,13	0,12
Distância Intra-cluster media	4,68	4,35	3,96	3,83	3,71

Fonte: Resultados originais da pesquisa

Na sequência, as Figuras 7 e 8, exibem uma representação bidimensional dos dados, a partir da aplicação de dois métodos para a visualização dos clusters: “Principal Component Analysis” [PCA] e “t-distributed Stochastic Neighbor Embedding” [t-SNE].




Figura 7. Visualização dos Clusters com PCA (2D)

Fonte: Resultados originais da pesquisa

O gráfico de PCA evidenciou uma separação entre os grupos principais, permitindo observar como as variáveis analisadas contribuem para a formação dos clusters. Foi possível notar que os clusters se organizam em regiões distintas do plano, o que reforça a validade da segmentação realizada.




Figura 8. Visualização dos Clusters com t-SNE (2D)

Fonte: Resultados originais da pesquisa

Por outro lado, o gráfico de t-SNE, apesar de não preservar distâncias absolutas, evidenciou ainda mais a proximidade entre comerciantes com perfis semelhantes, agrupando-os de forma densa e bem definida.

Portanto, a partir dos dois gráficos, pode-se observar a existência de seis clusters distintos, sendo o cluster 1, de coloração laranja, o com maior densidade de pontos, o que indica a existência de um grupo mais populoso. Enquanto, o cluster 5 contém poucos pontos, o que numa outra etapa do estudo, pode ser analisado afim de se perceber características mais específicas ou até “outliers”.

Tabela 4. Distribuição de variáveis por cluster

Cluster	Total	Percentual (%)
0	41	10,76
1	181	47,51
2	39	10,24
3	40	10,5
4	78	20,47
5	2	0,52

Fonte: Resultados originais da pesquisa

Na Tabela 4, em termos numéricos, pode-se analisar que o cluster 1 representa quase metade da amostra total (47,51%), sendo o grupo mais numeroso identificado pela segmentação e que dependendo da intenção de compra, é um público-alvo que merece atenção estratégica.

Já na Tabela 5, podemos ver as informações sobre as variáveis que compõem especificamente o cluster 1, com o objetivo de destacar as características que influenciaram a formação deste agrupamento:

Tabela 5. Perfil do Cluster 1

Categoria	Valor	Percentual (%)
Gênero	Female	61,88
	Male	38,12
Faixa Etária do Respondente	<= 30 years	25,97
	31-40 years	25,97
	41-50 years	35,91
	51-60 years	11,6
	>= 61 years	0,55
	Senior High School	54,14
Educação	Bachelor	39,23
	Master	3,31
	Junior High School	2,21
	Doctor	0,55
	Elementary School	0,55
Cargo	Owner	90,06
	Management team	9,94

Tempo de Atuação	<= 5 years	86,74
	6-10 years	3,87
	11-15 years	7,73
	>= 21 years	1,66
Força de Trabalho Ativa	1-4 workers	94,48
	5-19 workers	4,97
	20-99 workers	0,55
	<= 5 years	87,29
Idade da MSME	6-10 years	2,76
	11-15 years	7,18
	16-20 years	1,1
	21-25 years	1,66
Parcerias Duplas [DP]	Nunca fez parceria	70,72
	MSME-Governo	28,18
	MSME-Governo (outra entrada)	1,1
	Nunca fez parceria	89,5
Parcerias Triplas [TP]	MSME-Governo-Indústria	8,84
	MSME-Governo-Universidade	1,66

Fonte: Resultados originais da pesquisa

Complementando as informações obtidas através da análise exploratória, pode-se analisar que o cluster 1 é composto predominantemente por mulheres (61,9%) na faixa etária de 31 a 50 anos (62%). A maioria possui ensino médio completo (54,1%) e são, em sua grande maioria, proprietárias de negócios (90%).

As empresas deste cluster são jovens e pequenas, com 87,3% tendo menos de 5 anos de existência e 94,5% operando com 1 a 4 colaboradores. Além disso, 70,7% não possuem parcerias institucionais, indicando um perfil mais independente.

Dessa forma, a aplicação do K-means demonstrou-se eficaz na proposta de segmentação e direcionamento do foco para definição do público-alvo.

Regressão Logística

A variável dependente utilizada neste modelo é dicotômica, representando a adoção (1) ou não adoção (0) da tecnologia digital nas operações empresariais. Inicialmente, verificou-se a proporcionalidade entre as categorias da variável-alvo para garantir uma distribuição minimamente balanceada entre os grupos analisados, o que é essencial para a robustez da regressão logística binária.

Tabela 6. Proporcionalidade da variável dependente

Variável	Quantidade	Percentual (%)
1	270	70,86
0	111	29,14

Fonte: Resultados originais da pesquisa

Antes da modelagem, os dados passaram por uma etapa de pré-processamento, na qual foram criadas variáveis “dummies” para as variáveis categóricas, além de garantir que todos os campos numéricos estavam com o tipo de dado adequado e livres de valores ausentes ou infinitos. Em seguida, para reduzir problemas de multicolinearidade, foi calculado o VIF para as 31 variáveis independentes iniciais. As variáveis com VIF superior a 5 foram removidas, resultando em um subconjunto com 27 variáveis. Esta prática está alinhada à literatura, que recomenda a remoção de variáveis com colinearidade elevada para preservar a qualidade das estimativas do modelo.

Tabela 7. Variáveis com VIF < 5

ID	Variável	VIF
0	Working period_16-20 years	2.52
1	Working period_<= 5 years	2.48
2	Position_Owner	2.46
3	Position_Others	2.43
4	Triple partnership (TP)_Never partnered	2.30
5	Respondent Age_<= 30 years	2.26
6	Working period_>= 21 years	2.24
7	MSME age_6-10 years	2.20
8	MSME age_21-25 years	2.11
9	MSME age_16-20 years	2.09
10	Triple partnership (TP)_MSME-Industry-University	1.92
11	Respondent Age_41-50 years	1.75
12	Double partnership (DP)_MSME-University	1.51
13	Double partnership (DP)_MSME-Government	1.47
14	Triple partnership (TP)_MSME-Government-University	1.43
15	Respondent Age_51-60 years	1.42
16	Current active workforce_20-99 workers	1.40
17	Education_Master	1.21
18	Double partnership (DP)_MSME-Industry	1.19
19	Current active workforce_5-19 workers	1.19
20	Education_Senior High School	1.18
21	Gender_Male	1.11
22	Education_Junior High School	1.11
23	Education_Doctor	1.04
24	Respondent Age_>=61 years	1.04
25	Education_Elementary School	1.04
26	MSME age_>=30 years	1.03

Fonte: Resultados originais da pesquisa

Posteriormente, foi aplicada a técnica RFE, com o objetivo de selecionar as 15 variáveis mais relevantes para previsão da variável-alvo.

Tabela 8. Variáveis selecionadas pelo RFE

ID	Variável
0	Respondent Age_51-60 years
1	Respondent Age_<= 30 years
2	Respondent Age_>=61 years
3	Education_Elementay School
4	Education_Master
5	Education_Senior High School
6	Position_Owner
7	Working period_<= 5 years
8	MSME age_16-20 years
9	MSME age_21-25 years
10	MSME age_6-10 years
11	MSME age_>=30 years
12	Double partnership (DP)_MSME-Industry
13	Double partnership (DP)_MSME-University
14	Triple partnership (TP)_MSME-Government-Univer...

Fonte: Resultados originais da pesquisa

Para refinar ainda mais o conjunto de preditores, utilizou-se a estratégia de eliminação stepwise com base nos valores de significância estatística (p-valor). A cada iteração, a variável com menor contribuição estatística era removida até que todas as variáveis restantes apresentassem $p < 0,05$, resultando na especificação final do modelo, conforme apresentado na Tabela 10.

Tabela 10. Resultado da Regressão Logística

Variable	coef	std err	z	P> z	0.025	0.975
const	-0,2948	0,332	-0,888	0,375	-0,946	0,356
Respondent Age_<= 30 years	0,989	0,34	2,906	0,004	0,322	1,656
Position_Owner	0,8953	0,337	2,658	0,008	0,235	1,555
Double partnership (DP)_MSME-Industry	0,9684	0,479	2,022	0,043	0,03	1,907
Double partnership (DP)_MSME-University	0,8861	0,531	1,667	0,095	-0,156	1,928

Fonte: Resultados originais da pesquisa

Ao analisar o nível de significância estatística considerando a variável tODTA como variável dependente, pode-se observar os seguintes fatores:

- A variável “Respondent Age $\leq$ 30 years” apresentou um p-valor de 0,004, podendo indicar que lideranças mais jovens estão mais propensas a adoção de tecnologia.
- A variável “Position_Owner” também se destacou com p-valor de 0,008, sugerindo que proprietários exercem influência direta sobre essa decisão.

- Já a “Double partnership (DP)_MSME-Industry” teve p-valor de 0,043, apontando que colaborações com o setor industrial aumentam significativamente as chances de adoção tecnológica.
- Por fim, a variável “Double partnership (DP)_MSME-University” apresentou p-valor de 0,095, acima do nível de significância convencional, mas foi mantida no modelo pelo método stepwise, o que indica contribuição relevante no ajuste geral. Seu coeficiente positivo sugere uma tendência de maior propensão à adoção tecnológica entre empresas com esse tipo de parceria, o que reforça a importância de considerá-la.

Com os coeficientes estimados, procedeu-se à interpretação em termos de razão de chances. E os dados apresentados na Tabela 11, reforçam que lideranças com até 30 anos, proprietários e empresas com parceria com a indústria têm, respectivamente, 2,69, 2,45 e 2,63 vezes mais chances de adotar tecnologia. Já a parceria com universidades apresenta uma chance 2,43 vezes maior, embora com intervalo de confiança mais amplo.

Tabela 11. Razões de Chance (Odds Ratios)

Variável	Coeficiente (log-odds)	Odds Ratio	IC 2.5%	IC 97.5%
const	-0.294803	0.744678	0.388403	1.427759
Respondent Age_<= 30 years	0.988970	2.688464	1.379916	5.237882
Position_Owner	0.895297	2.448063	1.265087	4.737233
Double partnership (DP)_MSME-Industry	0.968392	2.633706	1.029998	6.734387
Double partnership (DP)_MSME-University	0.886076	2.425594	0.855948	6.873667

Fonte: Resultados originais da pesquisa

Partindo desse modelo foi possível gerar a matriz de confusão, de forma a verificar a quantidade de acertos entre o modelo estimado e os dados reais. Utilizando um cutoff de 0,5, a taxa de acerto foi moderadamente satisfatória, com uma acurácia de cerca de 69%.




Figura 9. Matriz de confusão

Fonte: Resultados originais da pesquisa

A partir da matriz de confusão, pode-se calcular a sensibilidade e especificidade. A sensibilidade foi de 89%, indicando que o modelo conseguiu identificar corretamente a maioria dos casos de adoção de tecnologia. No entanto, a especificidade foi de apenas 18%, o que sugere que o modelo teve uma performance baixa ao identificar corretamente os casos de não adoção.

A análise da área da curva ROC, reforça a interpretação dos resultados obtidos pelo modelo, uma vez que observa-se que a curva se posiciona à esquerda e acima da linha diagonal, que representa o desempenho de um modelo aleatório, indicando que o modelo apresenta bom desempenho na capacidade de distinguir quem adotaria tecnologia, conforme ilustrado na Figura 10.




Figura 10. Curva ROC

Fonte: Resultados originais da pesquisa

Estudos recentes têm explorado diferentes abordagens de segmentação de clientes com o uso de “machine learning”, reforçando a relevância do tema e a aplicabilidade de técnicas como a clusterização. Trabalhos como os de Santana et al. (2024) e Santana Junior e Barbosa (2024) utilizaram o modelo RFM (Recência, Frequência e Valor) para estruturar a segmentação, evidenciando a eficácia da clusterização na definição de perfis de clientes e na personalização de estratégias comerciais. Embora o presente estudo tenha adotado variáveis distintas, voltadas ao perfil dos empreendedores e características das PMEs, a aplicação do método K-means revelou-se igualmente eficaz na identificação de grupos com diferentes níveis de propensão à adoção tecnológica.

Além disso, o trabalho de Terra et al. (2024) reforça, por meio de revisão sistemática da literatura, a importância da escolha criteriosa de variáveis e frameworks no processo de segmentação, o que vai ao encontro da proposta deste estudo, que buscou combinar análise

exploratória, clusterização e regressão logística para compreender os fatores que influenciam a adoção tecnológica entre PMEs. Dentre outras referências, essas aqui citadas contribuem para validar a abordagem metodológica adotada e abrem caminhos para aprofundar futuras análises comparativas.

Considerações Finais

A partir da análise de um conjunto de dados composto por 381 registros e 38 variáveis categóricas e numéricas, e aplicando inicialmente a técnica de análise exploratória para conhecimento dos dados, o presente estudo foi conduzido em duas etapas.

Na primeira etapa, a aplicação do método de clusterização K-means permitiu identificar um público-alvo com características associadas a um maior potencial de adoção tecnológica. Esse grupo esteve composto, em sua maioria, por indivíduos com idade entre 31 e 50 anos (62%), com ensino médio completo (54,1%), proprietários de microempresas (90%), com até quatro colaboradores (94,5%) e com tempo de operação inferior a cinco anos (87,3%).

Na segunda etapa, em complemento ao estudo, e com o auxílio do modelo de regressão logística aplicado ao mesmo dataset — reduzido para 26,31% das variáveis — e classificado como 70,86% (adoção tecnológica) e 29,14% (não adoção), foi possível observar uma acurácia de 69% e sensibilidade de 89%, indicando boa capacidade de prever corretamente os casos de adoção tecnológica.

Como resultado, o método de clusterização possibilitou a identificação de um público-alvo específico com tendência à adoção tecnológica, enquanto o modelo de regressão logística apresentou bom desempenho preditivo.

É importante destacar que, embora a proposta inicial do estudo fosse realizar uma pesquisa de campo para coletar dados reais sobre os responsáveis por PMEs em Portugal, as limitações enfrentadas - como a baixa taxa de resposta ao questionário online e a resistência à participação presencial, optou-se pela utilização de uma base de dados disponibilizada na plataforma Kaggle, que apresentava estrutura semelhante e alinhada ao objetivo da pesquisa.

Para estudos futuros, sugere-se integrar as etapas de clusterização e regressão para verificar se o modelo combinado apresenta melhor performance; aplicar o estudo a um dataset maior e mais diversificado, considerando também a inclusão de variáveis mais aderentes ao objetivo proposto; explorar formas alternativas de coleta de dados, como parcerias com associações locais para aumentar a adesão dos respondentes; e avaliar o uso de outros modelos preditivos, dado o baixo desempenho na previsão dos casos de não adoção, mesmo com a variação do *cutoff*.

Agradecimento

Primeiramente, agradeço a Deus, pelo fôlego de vida diário. Ao meu esposo, que caminha ao meu lado no processo contínuo de evolução, tal como um modelo de machine learning que, a cada iteração, ajusta seus parâmetros para alcançar melhores resultados. Ao meu filho, que é minha maior fonte de inspiração e motivação. À minha família e amigos, pelo suporte em todas as fases desta jornada. À minha amiga Ana Luiza, que, depois de explorarmos juntas os caminhos da Engenharia Química, aceitou o desafio de desbravarmos o mundo dos dados. E, por fim, mas tão importante quanto, ao meu orientador, Mestre Guilherme, pela orientação dedicada e essencial para a construção deste trabalho.

Referências

Bianchini, M.; Michalkova V. 2019. Data Analytics in SMEs: Trends and Policies. OECD SME and Entrepreneurship Papers. Disponível em: <https://doi.org/10.1787/1de6c6a7-en>. Acesso em: 10 jan. 2025.

Carneiro, D. A. 2017. Perfil do empreendedor social brasileiro: estudo comparativo entre Brasil e Portugal. Dissertação de Mestrado em Empreendedorismo e Internacionalização. Instituto Superior de Contabilidade e Administração do Porto, Instituto Politécnico do Porto, Portugal.

European Commission. 2013. Regional policy for smart growth of SMEs. Disponível em: <https://data.europa.eu/doi/10.2785/47226>. Acesso em: 10 jan. 2025.

Fávero, L.P.; Belfiore, P. 2017. Manual de análise de dados: estatística e modelagem multivariada com excel, SPSS e Stata. Editora Elsevier, Rio de Janeiro, RJ, Brasil.

Junior, L. A. S. 2021. Uso de machine learning para classificação de fornecedores no contexto da data science. Dissertação de Mestrado em Engenharia de Produção. Universidade Federal de Itajubá, Itajubá, Minas Gerais, Brasil.

Klein, V. B.; Todesco, J. L. 2020. Transformação digital: desafios e oportunidades para PMEs. Anais do Congresso Internacional de Conhecimento e Inovação 1: 1-16.

Mourão, V. D. G. 2022. Estudo comparativo entre técnicas de machine learning para classificação do tomador PJ – MPE (Micro e Pequenas Empresas). Dissertação de Mestrado em Economia. Universidade de Brasília, Faculdade de Administração, Contabilidade e Economia, Departamento de Economia, Brasília, Brasil.

Oliveira, S. K. P.; Bertipaglia, W. D. P.; Ducatti, J. A. 2023. Ciência de Dados para Micro e Pequenas Empresas. Faculdade de Tecnologia de São José do Rio Preto, São Paulo, Brasil.

Santana Junior, G. F.; Barbosa, Y. A. M. 2023. Segmentação de clientes e otimização de estratégias: abordagens avançadas com análise RFM e algoritmos de clusterização. João Pessoa: Universidade Federal da Paraíba (UFPB), Centro de Informática.

SANTANA, L. H. B. de et al. Utilização inovadora do machine learning para a segmentação da carteira de clientes em uma empresa de hortifrutigranjeiros de grande porte. Caderno de Pesquisa Interdisciplinar em Ciências Humanas, v. 5, n. 1, 2023. DOI: <https://doi.org/10.21166/cpitt.v5i1.4918>. ISSN: 2763-5449.

TERRA, A. V. et al. Apoio multicritério à decisão e machine learning: análise bibliométrica aplicada na segmentação de clientes. In: XLIV ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO – ENEGEP, 2024, Porto Alegre. Anais [...]. Rio de Janeiro: ABEPRO, 2024. Tema: Reindustrialização no Brasil.

Tukey, J.W. 1977. Exploratory Data Analysis. Addison-Wesley, Reading, MA, EUA.

World Economic Forum. 2023. Data Unleashed: Empowering Small and Medium Enterprises (SMEs) for Innovation and Success. Disponível em: [https://www3.weforum.org/docs/WEF_Data_Unleashed_Empowering_Small_and_Medium_Enterprises_\(SMEs\)_for_Innovation_and_Success_2023.pdf](https://www3.weforum.org/docs/WEF_Data_Unleashed_Empowering_Small_and_Medium_Enterprises_(SMEs)_for_Innovation_and_Success_2023.pdf). Acesso em: 10 jan. 2025.