

/Análise comparativa de modelos preditivos para risco de crédito

Vinícius Petitemberte Osorio da Silva¹; Guilherme André Peleglini Rocha²

¹ Bacharel em engenharia de produção. R. Sergio Fernandes Borges Soares – Distrito Industrial; 13054-709
Campinas, SP, Brasil

² Mestre em economia aplicada. Av. Pádua Dias, 11 – Agronomia; 13418-900 Piracicaba, SP, Brasil

Análise comparativa de modelos preditivos para risco de crédito

Resumo

O risco de crédito representa um dos principais desafios para instituições financeiras, exigindo o uso de modelos preditivos cada vez mais eficientes na identificação de clientes com maior probabilidade de inadimplência. Este trabalho teve como objetivo geral comparar o desempenho de diferentes modelos preditivos aplicados à avaliação de risco de crédito, com foco em identificar a técnica mais eficaz para essa tarefa. Foram analisados cinco algoritmos: Regressão Logística, “Random Forest”, XGBoost, CatBoost e LightGBM. A metodologia envolveu a utilização de uma base de dados real de 2.260.701 observações e 150 colunas, contendo informações históricas de empréstimos, seguida por etapas de preparação dos dados, definição do período amostral, limpeza dos dados, treinamento dos modelos e avaliação de desempenho. As métricas adotadas para a comparação incluíram AUC-ROC, KS e análise do “bad rate” por decil. Os resultados demonstraram que os modelos baseados em “gradient boosting”, especialmente Catboost e LightGBM, apresentaram desempenho superior em relação aos demais, com maior poder discriminante e estabilidade nos resultados. A Regressão Logística e o “Random Forest”, apesar de apresentarem desempenho ligeiramente inferior, também apresentaram resultados satisfatórios na discriminação de clientes conforme o perfil de risco. A adoção de algoritmos mais avançados pode contribuir significativamente para a melhoria da acurácia preditiva no risco de crédito, desde que acompanhada por uma adequada preparação dos dados e validação robusta dos modelos.

Palavras-chave: Aprendizado de máquina, Regressão Logística; “Gradient Boosting”; “Random Forest”; “Credit Scoring”.

Comparative Analysis of Predictive Models for Credit Risk

Abstract

Credit risk represents one of the main challenges for financial institutions, requiring increasingly efficient predictive models to identify customers with a higher probability of default. This study aimed to compare the performance of different predictive models applied to credit risk assessment, focusing on identifying the most effective technique for this task. Five algorithms were analyzed: Logistic Regression, Random Forest, XGBoost, CatBoost, and LightGBM. The methodology involved the use of a real dataset with 2,260,701 observations and 150 columns, containing historical loan information, followed by data preparation steps, sample period definition, data cleaning, model training, and performance evaluation. The metrics used for comparison included AUC-ROC, KS, and bad rate analysis by decile. The results showed that gradient boosting-based models, especially CatBoost and LightGBM, outperformed the others, offering greater discriminative power and result stability. Logistic Regression and Random Forest, although slightly less accurate, also provided satisfactory results in classifying customers according to their risk profiles. It was concluded that the adoption of more advanced algorithms can significantly contribute to improving predictive accuracy in credit risk, provided it is supported by appropriate data preparation and robust model validation.

Keywords: Machine Learning, Logistic Regression; “Gradient Boosting”; “Random Forest”; Credit Scoring.

Introdução

A concessão de crédito é uma atividade vital no sistema bancário. Instituições financeiras prosperam através do empréstimo de dinheiro para empresas ou indivíduos, que prometem pagar o montante do valor tomado acrescido de juros, (Montevechi et al. 2024). No ambiente dinâmico das instituições financeiras, a gestão do risco de crédito é um fator crucial para a estabilidade, rentabilidade e a confiança. A mensuração do risco de crédito envolve a avaliação da probabilidade de um agente tomador de crédito não honrar com as obrigações originalmente pactuadas. Esta avaliação é um ponto crítico para gestão do risco do portfólio e para a decisão das políticas de concessão de crédito, (Bello, 2023).

No passado, as decisões de crédito eram tipicamente tomadas com base em conhecimentos prévios de analistas humanos, sendo suscetíveis à subjetividade, problemas de consistências e vieses comportamentais. Conforme o crescimento do mercado de crédito e do aumento da competitividade entre as instituições financeiras, métodos estatísticos e computacionais proporcionados pelo avanço na tecnologia começaram a ser cada vez mais relevantes nesta indústria. Como resultado, estas técnicas passaram a complementar ou substituir o julgamento humano no processo de concessão de crédito, (Suhadolnik, Nicolas, Jo Ueyama, Sergio Da Silva, 2023.)

Uma abordagem comum para avaliação do risco de crédito é o “credit scoring”, onde tomadores de crédito possuem uma nota baseada em seu histórico de crédito e outros fatores relevantes, como a condição financeira, renda, garantias e fatores macroeconômicos. Técnicas estatísticas, como regressão logística, são comumente utilizadas para modelar a relação entre as características de um agente tomador de crédito com o evento de inadimplência, (Tekic et al. 2021). O objetivo do “credit scoring” é segmentar os solicitantes de crédito em “bons pagadores” (aqueles com alta probabilidade de realizar os pagamentos em dia) e “maus pagadores” (aqueles com alta probabilidade de inadimplir). Com a alta competitividade do mercado, as instituições financeiras receberam ainda mais incentivos para implementar técnicas de “score” de crédito para seus portfólios. O investimento em modelos de crédito contribui diretamente para maximização dos retornos, através da redução das perdas e inadimplência, eficiência na alocação de Capital, agilidade na tomada de decisão, conformidade regulamentar, redução de custos operacionais, otimização de processos e adaptação ao Mercado e Inovações, (Brown e Mues, 2012).

Os acordos de Basiléia, principalmente a partir do segundo, impulsionaram o crescimento do uso dos “scores” de crédito, não apenas para a tomada de decisão da concessão de crédito, mas para propósitos de gerenciamento de risco. O acordo de Basiléia II introduziu três pilares fundamentais: O primeiro trata dos requisitos mínimos de capital, o

segundo; da supervisão regulatória; e o terceiro, da disciplina do mercado. Com foco na estabilidade financeira, este acordo incentivou as instituições financeiras a adotarem técnicas avançadas de avaliação e gestão de risco, para garantir que seus níveis de capital estivessem adequadamente alinhados ao risco dos seus portfólios de crédito. Aquelas que optam por modelos internos de avaliação de risco possuem maior flexibilidade na alocação de capital, apresentando possibilidade de redução no capital regulatório. Dessa forma, os acordos de Basiléia incentivaram e pressionaram as instituições financeiras a adotarem modelos analíticos mais robustos e modernos para avaliação de risco, (Louzada, Ara e Fernandes, 2016).

Dastile, Celik e Potsane (2020) afirmam que, tradicionalmente, as instituições financeiras optam pela regressão logística para o cálculo do “score” de seus clientes. Esta escolha é tomada devido à simplicidade e transparência da técnica. Enquanto as técnicas estatísticas tradicionais se provaram eficazes até certo ponto, o uso de “machine learning” se expandiu significativamente no setor financeiro nos últimos anos, especialmente na avaliação de risco de crédito. Diferente dos métodos estatísticos clássicos, modelos de “machine learning” se mostram mais eficazes para capturar a complexidade do mercado financeiro e o vasto volume de dados disponíveis.

“Machine Learning” é uma área de pesquisa da inteligência artificial focada no desenvolvimento de modelos que usam um conjunto de dados de treino para aumentar a eficiência de tarefas específicas. Estes modelos são adequados para modelar grandes volumes de dados, dado à sua otimização da acurácia das predições. A captura das interações complexas entre as variáveis, sem a necessidade de suposições lineares, permite que as instituições financeiras façam previsões mais precisas sobre o comportamento dos tomadores de crédito. Algoritmos como árvores de decisão, “Random forest”, gradiente “boosting” e redes neurais têm mostrado resultados promissores na identificação de padrões e na classificação em categorias de risco, oferecendo base mais sólida para a tomada de decisão, (Kanaparthi, 2023).

O objetivo deste estudo é realizar uma análise comparativa do desempenho de diferentes algoritmos de modelagem de probabilidade de inadimplência, utilizando dados reais e aplicando técnicas consagradas na literatura, tais como regressão logística, “bagging” e “boosting”. A pesquisa busca avaliar a eficácia preditiva e a robustez de cada abordagem, considerando métricas de desempenho e aspectos interpretativos, com foco na aplicabilidade para análise de crédito e previsão de inadimplência.

Metodologia ou Material e Métodos

A presente pesquisa será conduzida a partir de dados¹ fornecidos pela Lending Club, uma das principais plataformas de empréstimos do tipo peer-to-peer (P2P) no cenário internacional. Fundada nos Estados Unidos, a organização atua como um marketplace financeiro digital, cuja função principal é intermediar, por meio de tecnologia, a concessão de crédito entre pessoas físicas e investidores, sem a necessidade da participação de instituições financeiras tradicionais. O modelo de negócios adotado pela Lending Club está inserido em um contexto de transformação digital no setor financeiro, caracterizado pela desintermediação e pela utilização de algoritmos para análise de risco, precificação de crédito e gestão de transações.

Essa modalidade de crédito, conhecida como P2P “lending”, tem se consolidado como uma alternativa relevante aos sistemas convencionais de financiamento, tanto pela maior acessibilidade ao crédito quanto pelo potencial de retorno para investidores. A Lending Club, nesse contexto, destaca-se por sua expressiva atuação no mercado, tendo originado mais de 90 bilhões de dólares em empréstimos apenas nos quatro primeiros meses do ano de 2024, o que evidencia a robustez de sua base de dados e a relevância da plataforma para estudos relacionados à avaliação de risco de crédito, inadimplência e comportamento de tomadores. Assim, os dados disponibilizados por essa instituição representam uma fonte rica e confiável para o desenvolvimento de análises quantitativas no âmbito da ciência de dados aplicada às finanças.

As etapas para o desenvolvimento do modelo são:

- Entendimento e preparação dos dados: Esta etapa envolve a exploração e o pré-processamento dos dados, incluindo a definição da variável resposta, do período amostral e a limpeza e tratamento dos dados.
- Treinamento dos modelos propostos: Treinamento dos modelos preditivos de inadimplência, utilizando as técnicas de “random forest”, catboost, XGboost, lightgbm e regressão logística.
- Validação dos resultados dos modelos desenvolvidos: A validação será realizada no conjunto de teste, utilizando as métricas da área sob a curva ROC, KS e a análise do desempenho do “score” por decil.

Base de dados

Os dados disponibilizados pelas plataformas de P2P apresentam alto potencial para o treinamento de algoritmos de “machine learning”, devido ao seu grande volume de dados reais. A base de dados¹ inicial utilizada neste Trabalho possui o histórico de empréstimos pessoais concedidos entre 2007 até 2018, apresenta 2.260.701 observações e 150 colunas, contendo as informações disponíveis no momento da concessão do crédito.

Considerando que a base de dados utilizada representa uma fotografia dos contratos de empréstimo em um determinado momento no tempo, e não contém informações padronizadas de tempo decorrido desde a concessão, optou-se por selecionar apenas os contratos de empréstimos liquidados. Essa decisão foi necessária para garantir a confiabilidade da variável resposta, denominada “fl_bom”, que assume duas categorias: 1, para os contratos completamente pagos, e 0 para os contratos que foram enviados para perda. Os empréstimos que não estão liquidados não possuem um desfecho conhecido, o que comprometeria a acurácia das métricas de avaliação e a consistência do modelo preditivo. Ao restringir a análise aos contratos já encerrados, consideramos como inadimplentes aqueles que foram enviados para perda. Essa restrição assegura que todos os registros considerados no estudo têm uma definição clara quanto ao seu status final, permitindo a aplicação correta dos algoritmos de classificação supervisionada e das métricas de avaliação de desempenho.

Definição do período amostral

A seleção do período de análise com base na estabilidade do percentual de inadimplência e na quantidade de observações disponíveis é uma prática recomendada na construção de modelos preditivos de risco de crédito, pois garante maior representatividade da amostra e robustez nos resultados obtidos (FÜHR, 2018). Para a definição da amostra de desenvolvimento, foi realizada uma análise do percentual de empréstimos enviados a perda ao longo do tempo, segmentado por ano e mês da concessão. O objetivo dessa análise foi assegurar que todo o período amostral apresentasse um comportamento estável em relação à inadimplência, evitando a inclusão de intervalos impactados por mudanças significativas nas políticas de concessão de crédito. Tais alterações poderiam distorcer os padrões de risco observados e, conseqüentemente, comprometer a generalização dos modelos preditivos desenvolvidos. A figura 1 representa a série temporal do percentual de contratos enviados para Perda por ano e mês da concessão, enquanto a figura 2 representa a quantidade de observações em cada data.




Figura 1. Série temporal do percentual de inadimplência por ano e mês da concessão.

Fonte: Dados originais da pesquisa




Figura 2: Quantidade de empréstimos por ano e mês da concessão.

Fonte: Dados originais da pesquisa

Através da análise gráfica das figuras 1 e 2, definiu-se que os contratos concedidos entre julho de 2014 e dezembro de 2015 serão utilizados para o desenvolvimento dos modelos. Esse intervalo foi selecionado por apresentar uma quantidade relevante de observações, totalizando 499.178 registros, e por demonstrar estabilidade no percentual de contratos enviados para perda, com média de 19,9% no período, variando entre um mínimo de 18,5% (dezembro de 2014) e um máximo de 20,9% (dezembro de 2015). Após esse período, observou-se uma redução significativa na quantidade de contratos liquidados, o que se deve ao fato de serem operações mais recentes, e, portanto, a maioria ainda pode não ter chegado no seu prazo final.

Limpeza dos dados

O processo de limpeza de dados é uma etapa fundamental no desenvolvimento de modelos preditivos, pois garante a integridade e a qualidade das informações utilizadas na análise. Entre as etapas mais relevantes estão: a remoção de registros duplicados, que evita a super-representação de determinados perfis e o tratamento de valores ausentes, que pode envolver desde a exclusão de variáveis pouco informativas até a imputação com métodos estatísticos. A negligência nessas etapas pode comprometer significativamente o desempenho dos modelos, além de introduzir viés nos resultados, (Raschka, 2015).

Durante o processo de limpeza dos dados, constatou-se que a base de empréstimos não apresenta registros duplicados. No entanto, foi identificada a presença de variáveis com elevado percentual de valores ausentes. A ocorrência de dados nulos pode estar relacionada a diferentes fatores, tais como:

- O não preenchimento da informação por parte do solicitante no momento da aplicação do crédito;
- A ausência do evento representado pela variável, indicando que a informação não se aplica àquele contrato (por exemplo, número de meses desde a última inadimplência para um cliente sem histórico de atraso);
- Diferenças nos processos de coleta ou registro de dados ao longo do tempo, refletindo alterações operacionais ou mudanças nas políticas internas da instituição.

Como etapa inicial de tratamento, optou-se por excluir 53 variáveis que apresentavam mais de 90% de valores nulos, por não fornecerem informação suficiente para contribuir de forma significativa na modelagem. Após essa filtragem, permaneceram 25 variáveis com proporções de dados ausentes entre 1% e 90%, as quais foram analisadas individualmente para definição da melhor abordagem de imputação ou categorização.

Com o objetivo de apoiar a definição da categorização das variáveis a partir da presença de valores nulos, será realizado o cálculo do Risco Relativo [RR] para todas as variáveis que apresentem mais de 5% de registros nulos. O RR será utilizado para avaliar a associação entre a presença (ou ausência) de informação e a inadimplência, categorizando cada variável em dois grupos: nulo e não nulo. Esse procedimento é frequentemente adotado em estudos que buscam investigar o impacto dos dados faltantes na modelagem de risco de crédito, onde a ausência de informações pode influenciar significativamente a capacidade preditiva do modelo e a precisão dos resultados, (Vieira, 2023).

O Risco Relativo é uma métrica que expressa a razão entre a probabilidade de ocorrência de um evento (neste caso, a inadimplência) em dois grupos distintos, calculado por meio da equação 1:

$$RR = \frac{P(\text{inadimplência} | \text{valor nulo})}{P(\text{inadimplência} | \text{valor não nulo})} \quad (1)$$

em que $P(\text{inadimplência} | \text{valor nulo})$: é a proporção de inadimplentes entre os registros com valor nulo; $P(\text{inadimplência} | \text{valor não nulo})$: é a proporção de inadimplentes entre os registros com valor preenchido.

A categoria “não nulo” será utilizada como referência (denominador), permitindo interpretar o RR da seguinte forma:

- $RR > 1$: A presença de valor nulo está associada a um aumento no risco de inadimplência;
- $RR = 1$: A ausência de informação não apresenta associação significativa com o risco de inadimplência;
- $RR < 1$: A ausência de informação está associada a um menor risco de inadimplência.

Para fins de categorização, foram selecionadas apenas três variáveis cuja ausência de informação apresentou associação significativa com a inadimplência, conforme os critérios estabelecidos de Risco Relativo ($RR \geq 1,2$ ou $RR \leq 0,8$). Esse resultado indica que, nesses casos, os valores nulos carregam informação relevante sobre o risco de crédito e, portanto, foram tratados como uma categoria específica no modelo. Além disso, foi adotado um critério adicional de elegibilidade: a proporção de registros com valores ausentes deveria ser de, no mínimo, 5% do total da amostra, a fim de garantir representatividade estatística e robustez na análise. As demais 16 variáveis, cujos valores nulos não apresentaram impacto significativo sobre o risco ou que não atingiram o limite mínimo de frequência, foram excluídas da base final de modelagem. Por fim, 6 variáveis ainda apresentaram valores nulos, porém, representando menos de 0,1% da amostra, portanto, estas observações foram eliminadas da base, sendo possível manter as colunas sem que haja perda relevante de informação.

Por fim, foi conduzida uma análise criteriosa para identificar variáveis que contêm informações futuras, ou seja, atributos que não estariam disponíveis no momento da decisão de crédito. A presença dessas variáveis no conjunto de dados pode causar vazamento de informação (“data leakage”), comprometendo a integridade do modelo ao inflar artificialmente seu desempenho preditivo (Stock, Gregr, Chan, 2023). Como medida preventiva, foram excluídas 42 variáveis identificadas com esse tipo de viés temporal. A seguir, são apresentadas as variáveis finais selecionadas para o desenvolvimento do modelo, sendo a variável “fl_bom” definida como variável resposta, representando o desfecho de inadimplência do contrato.

Tabela 1: Descrição das variáveis selecionadas para o desenvolvimento do modelo

Variável	Descrição
fl_bom	Flag que indica se o contrato foi quitado completamente, sem o envio para perda
home_ownership	Status de propriedade da residência informado pelo mutuário
annual_inc	Renda anual autodeclarada fornecida pelo mutuário
verification_status	Status de verificação da renda pelo originador
purpose	Finalidade do empréstimo informada pelo solicitante
addr_state	Estado de residência do mutuário
dti	Índice de comprometimento de renda (dívidas/renda)
delinq_2yrs	Nº de inadimplências vencidas (>30 dias) nos últimos 2 anos
fico_range_low	Limite inferior da faixa de “score” FICO no momento da concessão
fico_range_high	Limite superior da faixa de “score” FICO no momento da concessão
inq_last_6mths	Nº de consultas recentes ao bureau (últimos 6 meses)
open_acc	Nº de contas de crédito abertas
pub_rec	Nº de registros públicos depreciativos
revol_bal	Saldo rotativo total de crédito
revol_util	Percentual de utilização do crédito rotativo disponível
total_acc	Nº total de linhas de crédito
acc_now_delinq	Nº de contas atualmente inadimplentes
tot_cur_bal	Saldo corrente total de todas as contas
acc_open_past_24mths	Contas abertas nos últimos 24 meses
bc_open_to_buy	Crédito disponível para compras em cartões bancários
bc_util	Percentual utilizado do limite de crédito dos cartões bancários
delinq_amnt	Valor total em inadimplência nas contas do mutuário
mo_sin_old_il_acct	Meses desde a abertura da conta de parcelamento mais antiga
mo_sin_old_rev_tl_op	Meses desde a abertura da conta rotativa mais antiga
mo_sin_rcnt_rev_tl_op	Meses desde a abertura da conta rotativa mais recente
mo_sin_rcnt_tl	Meses desde a abertura da conta mais recente
mort_acc	Nº de contas hipotecárias
mths_since_recent_bc	Meses desde a abertura do cartão bancário mais recente
mths_since_recent_inq	Meses desde a última consulta ao bureau
num_accts_ever_120_pd	Contas com histórico de atraso de 120+ dias
num_actv_bc_tl	Nº de cartões bancários ativos
num_actv_rev_tl	Nº de contas rotativas ativas
num_bc_sats	Nº de cartões bancários com desempenho satisfatório
num_bc_tl	Total de contas de cartão bancário
num_il_tl	Total de contas de crédito parcelado
num_op_rev_tl	Total de contas rotativas abertas
num_rev_accts	Nº total de contas rotativas
num_rev_tl_bal_gt_0	Contas rotativas com saldo positivo
num_sats	Nº de contas satisfatórias
num_tl_120dpd_2m	Contas com atraso de 120 dias nos últimos 2 meses
num_tl_30dpd	Contas com atraso de 30 dias (últimos 2 meses)
num_tl_90g_dpd_24m	Contas com atraso de 90+ dias nos últimos 24 meses
num_tl_op_past_12m	Contas abertas nos últimos 12 meses
pct_tl_nvr_dlq	Porcentagem de contas sem histórico de inadimplência
percent_bc_gt_75	Porcentagem de cartões com uso acima de 75% do limite
pub_rec_bankruptcies	Nº de falências registradas

tax_liens	Nº de ônus fiscais registrados
tot_hi_cred_lim	Limite total de crédito elevado registrado
total_bal_ex_mort	Saldo total excluindo contas hipotecárias
total_bc_limit	Limite total de crédito dos cartões bancários
total_il_high_credit_limit	Limite total dos empréstimos parcelados
mo_since_first_credit	Meses desde a primeira linha de crédito
fl_unemployed	Indicador se o cliente encontra desempregado

Seleção dos modelos

Após a etapa de tratamento e preparação dos dados, foi realizada a construção e o treinamento de diferentes algoritmos de aprendizado de máquina e regressão logística, com o objetivo de comparar seus desempenhos na predição do risco de crédito. O desempenho será medido em uma base de dados de “teste”, para garantir que não ocorra o “overfitting”, fenômeno que ocorre quando o modelo não é capaz de generalizar para dados não utilizados no treinamento. Portanto, o conjunto de dados foi dividido de forma aleatória em 80% para treinamento dos modelos e 20% para teste. Foram selecionados modelos de distintas abordagens, todos amplamente utilizados na modelagem de risco de crédito devido à sua eficácia e aplicabilidade comprovada, (Cuong, et. Al, 2025). Serão testados: regressão Logística, como técnica estatística clássica e amplamente utilizada em problemas de risco de crédito; “Random Forest”, como método de “ensemble” baseado em árvores de decisão com “bagging” e os modelos baseados em “boosting”: LightGBM, XGBoost e CatBoost, que representam o estado da arte em termos de desempenho preditivo e eficiência computacional (Coelho, Amorim e Camargos, 2021).

A comparação entre os algoritmos permitirá identificar a técnica mais eficaz para a base de dados em questão, considerando aspectos como capacidade discriminante, tratamentos dos dados necessários para cada técnica, robustez e interpretação.

Regressão logística

A técnica de regressão logística se caracteriza por descrever a relação de uma ou mais variáveis independentes (X) sobre uma variável dependente, em geral, dicotômica (Y), representando a ausência ou presença de alguma característica ou evento, (Hosmer, Lemeshow, 1989). Portanto, é adequada para a análise de risco de crédito, que avalia a ocorrência do evento de inadimplência. A expressão do modelo é apresentada na Equação:

$$\ln\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k \quad (2)$$

em que p é a probabilidade de que Y = 1 e X₁, X₂, ..., X_k são as variáveis independentes. β₀, β₁, β₂, ..., β_k são os coeficientes da regressão

Os coeficientes da regressão são medidas das variações na proporção das probabilidades, chamadas de razão de desigualdade e são estimados utilizando o método da Máxima Verossimilhança. Na prática, é comum trabalhar com a log-verossimilhança (equação 3), que é o logaritmo natural da função de verossimilhança. Isso simplifica o cálculo, principalmente porque transforma o produto de probabilidades em uma soma, tornando mais fácil a maximização (Satchidananda, Simha, 2006).

$$l(\theta) = \sum_{i=1}^n \log f(x_i|\theta) \quad (3)$$

em que $l(\theta)$ é a log-verossimilhança do modelo dado o parâmetro θ ; $\sum_{i=1}^n$ é a soma de todas as observações e $f(x_i|\theta)$ é a função de densidade de probabilidade associada à i -ésima observação x_i , condicionada aos parâmetros θ .

Em modelos de regressão logística, é fundamental que todas as variáveis explicativas sejam numéricas, pois o algoritmo baseia-se em operações matemáticas que requerem esse formato. Variáveis categóricas, portanto, precisam ser transformadas antes da modelagem. Uma técnica amplamente utilizada para esse propósito é o “One-Hot Encoding” (OHE), que converte cada categoria de uma variável em uma nova variável binária, indicando a presença (1) ou ausência (0) daquela categoria. Essa abordagem evita a introdução de ordens arbitrárias entre categorias, o que poderia ocorrer com outras técnicas de codificação. A aplicação do OHE é fundamental para garantir a correta interpretação dos coeficientes na regressão logística, especialmente quando se lida com variáveis categóricas nominais (Ohtoshi, 2003). Além disso, Carrizosa et al. (2021) discute que, embora o “One-Hot Encoding” possa aumentar a dimensionalidade do conjunto de dados, ele preserva a integridade da informação categórica e é preferível em situações em que a ordem natural entre categorias não existe.

A aplicação da regressão logística exige cuidados específicos no tratamento das variáveis explicativas para garantir a validade dos resultados. Um dos principais desafios é a presença de multicolinearidade entre as variáveis independentes, que pode distorcer as estimativas dos coeficientes e comprometer a interpretação do modelo. Para mitigar esse desafio, foram excluídas as variáveis com correlação de Pearson (equação 4) maior que 0,7 ou menor que -0,7. Para diagnosticar a multicolinearidade, é comum utilizar o Fator de Inflação da Variância [VIF], definido na equação 5, que quantifica o grau de colinearidade entre as variáveis. Valores de VIF superiores a 5 já indicam correlação elevada, sendo recomendável a exclusão ou transformação de variáveis (Nakamura, 2013).

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4)$$

em que r é o coeficiente de correlação de Pearson entre os dados amostrais x_i e y_i ; $\bar{x}$ é a média amostral da variável x ; $\bar{y}$ é a média amostral da variável y e n é o número de observações

$$Vif_j = \frac{1}{1 - R_j^2} \quad (5)$$

em que R_j^2 representa o coeficiente de determinação da regressão da variável X_j sobre as demais variáveis explicativas.

Além disso, a linearidade entre as variáveis independentes e o logito da variável dependente é uma suposição fundamental da regressão logística. Quando essa relação não é observada, transformações nas variáveis podem ser necessárias. No contexto de risco de crédito, uma técnica amplamente utilizada é o “Weight of Evidence” (WOE), que transforma variáveis categóricas ou contínuas em uma escala que reflete a relação entre a variável explicativa e a variável resposta (Anderson, 2007). Essa transformação facilita a interpretação dos coeficientes e melhora o desempenho do modelo, especialmente quando combinada com a codificação de variáveis categóricas e o tratamento de valores ausentes ou discrepantes. A fórmula do WOE para uma determinada categoria é demonstrada na equação 6:

$$WOE_i = \ln\left(\frac{(\text{Percentual de bons}_i)}{(\text{Percentual de maus}_i)}\right) \quad (6)$$

em que "bons" e "maus" referem-se, respectivamente, aos casos de não inadimplência e inadimplência.

Árvores de decisão

A técnica de árvores de decisão [DT] é amplamente utilizada para problemas de classificação, se destaca pela sua eficácia e facilidade de interpretação, sendo utilizadas em diversas áreas como processamento de imagens e aprendizado de máquina. (Jijo e Abdulazeez, 2021). O método segue uma série de perguntas que determinam a separação em cada nível, sendo os pontos de divisão derivados dessas perguntas e podendo assumir valores discretos, intervalos ou distribuições de probabilidade (Hartman, 2019). É uma técnica baseada em árvores, na qual qualquer caminho se inicia pela raiz é definido por uma sequência de separações dos dados até chegar em um resultado booleano. As divisões iterativas do conjunto de dados em subconjuntos mais homogêneos são realizadas através de critérios como o índice de Gini (equação 7) ou a entropia para problemas de classificação (equação 8).

$$Gini(D) = 1 - \sum_{i=1}^k p_i^2 \quad (7)$$

em que p_i é a proporção de elementos da classe i no conjunto de dados D e k é o número de classes

$$H(D) = - \sum_{i=1}^k p_i \log_2 p_i \quad (8)$$

em que p_i é a proporção de elementos da classe i no conjunto de dados D ; k é o número de classes e $\log_2$ é o logaritmo na base 2, que transforma a probabilidade em uma medida de "informação".

O algoritmo seleciona a variável que maximiza a separação entre as classes ou reduz a variância, criando nós de decisão e folhas que representam os resultados, conforme representado na figura 3. Esse processo continua até que um critério de parada seja atingido, como um número mínimo de amostras por nó ou profundidade máxima da árvore, (Sun, et. Al, 2022).




Figura 3. Representação de uma árvore de decisão

Fonte: Yousaf, et. Al, 2024

Random forest

O algoritmo “random forest” [RF], proposto por Breiman (2001), é um método de aprendizado de máquina baseado em ensemble que combina múltiplas árvores de decisão para melhorar a precisão e a robustez das previsões. Cada árvore é construída a partir de uma amostra aleatória com reposição “bootstrap” do conjunto de dados original, e, em cada nó, uma seleção aleatória de variáveis é considerada para determinar a melhor divisão.

A predição final do modelo é obtida por votação majoritária no caso de classificação ou pela média das previsões no caso de regressão. Esse processo reduz a variância dos modelos individuais, tornando o RF menos suscetível ao “overfitting”, especialmente em

conjuntos de dados com alta dimensionalidade ou colinearidade. Além disso, o RF é capaz de capturar interações não lineares entre variáveis e fornece uma medida da importância das variáveis para a predição.

Boosting

“Boosting” é uma técnica de aprendizado de máquina baseado em árvores que busca aumentar a precisão da previsão combinando vários modelos para formar um modelo forte. O processo funciona de maneira iterativa, onde cada novo modelo é treinado para corrigir os erros cometidos pelos modelos anteriores. Essa abordagem permite que o modelo capture padrões complexos nos dados e melhore progressivamente o desempenho preditivo. A ideia central é atribuir maior peso às observações que foram mal classificadas nas iterações anteriores, garantindo que o modelo se concentre nos casos mais difíceis e aumente sua capacidade de generalização, (Cao, Xu, Liang, Zhang, Li, 2010).

Segundo Friedman (2001), nos problemas de classificação binária modelo começa com uma previsão inicial (equação 9), que geralmente é uma constante que minimiza a função de perda. A função de perda comumente utilizada é a log-verossimilhança (equação 10), que mede quanto que o modelo está classificando corretamente na amostra. O gradiente (equação 11) é o erro cometido pelo modelo na previsão da iteração anterior, e é utilizado como variável resposta do modelo da iteração atual. Por fim, a equação 12 demonstra o modelo final, que é a soma das previsões dos modelos fracos ajustados nas iterações anteriores.

$$F_0(x) = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma) \quad (9)$$

em que $F_0(x)$ é a previsão inicial do modelo; γ é o valor predito; $L(y_i, \gamma)$ é a função de perda; y_i é a classe real da observação e n é o número de observações

$$L(y, F(x)) = \log(1 + \exp(-2yF(x))) \quad (10)$$

em que $L(y, F(x))$ é o valor da função de perda; y é a classe real da observação e $F(x)$ é o o valor predito pelo modelo para a entrada x

$$r_{im} = y_i - \frac{1}{1 + \exp(-F_{m-1}(x_i))} \quad (11)$$

em que r_{im} é o gradiente da observação i na iteração m ; y_i é a classe real da observação e $F_{m-1}(x_i)$ é a predição da iteração anterior

$$F(x) = F_0(x) + \sum_{m=1}^M v h_m(x) \quad (12)$$

em que $F(x)$ é a predição final do modelo, $F_0(x)$ é a previsão inicial; ν é a taxa de aprendizado, $h_m(x)$ é o modelo fraco ajustado na iteração m e M é o número total de iterações

Os algoritmos de “Boosting” são amplamente utilizados em diversas aplicações, como classificação, regressão e detecção de anomalias. Algumas das variantes mais conhecidas incluem “XGBoost”, “LightGBM” e “CatBoost”, cada uma com otimizações específicas para melhorar o desempenho e a eficiência computacional. O primeiro possui alta eficiência em bases estruturadas, possui ótima regularização e controle de “overfitting”, porém pode ser mais lento em grandes volumes de dados devido à busca dos melhores conjuntos de dados, consumindo mais memória. O segundo foi otimizado para ser rápido em grandes conjuntos de dados, porém, é mais suscetível ao “overfitting”. O terceiro é excelente para dados com muitas variáveis categóricas, possui um melhor tratamento de “overfitting” e funciona bem com bases grandes e pequenas, porém, requer mais ajustes de hiperparâmetros para alcançar o melhor desempenho, (Bentéjac, Csorgo e Muñoz, 2021).

Seleção das variáveis e otimização de hiper parâmetros

Antes do treinamento dos modelos, foi realizada uma etapa criteriosa de seleção de variáveis, com o objetivo de eliminar redundâncias, melhorar a explicabilidade e garantir a estabilidade dos modelos. Inicialmente, foram removidas variáveis numéricas com alta correlação entre si, a fim de mitigar problemas de multicolinearidade, especialmente relevantes para algoritmos lineares como a regressão logística. A presença de variáveis fortemente correlacionadas pode inflar a variância dos coeficientes estimados, dificultando a interpretação dos efeitos individuais e comprometendo a robustez do modelo, bem como aumentando o risco de “overfitting”, (Bhalaji, Kumar, Selvaraj, 2018).

Em seguida, para os modelos de árvores, foi aplicada a técnica de seleção recursiva de variáveis, que avalia iterativamente o impacto de cada variável no desempenho do modelo, removendo aquelas com menor importância preditiva. Essa abordagem contribui para reduzir o risco de “overfitting” e otimizar o desempenho dos algoritmos ao considerar apenas as variáveis mais relevantes para a previsão da inadimplência. Segundo Anand (2021), a aplicação da seleção recursiva de variáveis com validação cruzada utilizando estimadores de árvore de decisão demonstrou eficácia na redução do número de variáveis necessárias para alcançar alta acurácia, evidenciando a importância dessa técnica na construção de modelos preditivos robustos.

No caso específico da regressão logística, também foi realizada uma análise da linearidade entre as variáveis independentes contínuas e o logito da variável resposta, pressuposto fundamental para a validade do modelo, aplicando o WOE.

Por fim, após a definição das variáveis, foi conduzido o processo de otimização de hiper parâmetros com o uso da biblioteca Optuna, uma ferramenta moderna de otimização bayesiana baseada em busca sequencial. Essa técnica permite uma exploração eficiente do espaço de busca por meio de algoritmos adaptativos que aprendem com as tentativas anteriores. Essa etapa foi essencial para calibrar os principais parâmetros dos modelos de árvores, como taxa de aprendizado, número de estimadores e profundidade das árvores, maximizando seu desempenho com base em validação cruzada estratificada. Segundo Akiba et al. (2019), o Optuna se destaca por sua arquitetura flexível e eficiente, sendo amplamente utilizado em tarefas de otimização de hiper parâmetros em modelos de aprendizado de máquina.

Métricas para avaliação dos modelos

Dentre as métricas utilizadas para avaliar o desempenho dos modelos, destacam-se a estatística de Kolmogorov-Smirnov [KS] e a Área sob a Curva ROC [AUC]. A estatística KS mede a maior distância entre as distribuições acumuladas dos "score"s preditos para as classes inadimplente e adimplente. Matematicamente, é definida na equação 13:

$$KS = \max_x |F_1(x) - F_0(x)| \quad (13)$$

onde $F_1(x)$ representa a função de distribuição acumulada do "score" da classe positiva, e $F_0(x)$ a distribuição acumulada do "score" da classe negativa

Quanto maior essa distância, maior a capacidade do modelo de distinguir corretamente os dois grupos. De acordo com Zheng (2019), o teste de KS é amplamente utilizado para verificar a separabilidade entre distribuições, sendo eficaz mesmo em contextos de dados com grande variabilidade.

Já a AUC

representa a probabilidade de o modelo atribuir um "score" maior a um contrato adimplente do que a um inadimplente escolhido aleatoriamente. Segundo Dong (2013), a AUC é considerada uma métrica robusta por ser independente de limiares e eficaz mesmo quando as classes estão desbalanceadas, sendo amplamente usada na comparação entre classificadores binários.

Complementarmente, a análise da inadimplência por decil, ou seja, a proporção de inadimplência dentro de cada um dos 10 grupos ordenados pelo "score", permite avaliar a capacidade de discriminação do modelo. Um bom modelo deve concentrar os casos de inadimplência nos primeiros decis, apresentando uma curva decrescente da taxa de inadimplência. Essa análise é útil para comparar modelos e para subsidiar políticas de corte

e estratégias de concessão, uma vez que permite visualizar claramente o poder de segregação entre bons e maus pagadores.

Resultados e Discussão

Nesta seção, são apresentados os resultados obtidos a partir da aplicação dos cinco modelos preditivos desenvolvidos: Regressão Logística, Random Forest, XGBoost, CatBoost e LightGBM. O desempenho dos modelos foi avaliado utilizando três métricas principais: *AUC*, *KS* e análise da taxa de inadimplência (“bad rate”) por decil. A tabela 2 apresenta de forma resumida o comparativo para as 3 métricas de avaliação:

Tabela 2: Quadro comparativo das métricas de avaliação no conjunto de teste.

Modelo	AUC	KS	Bad rate 1º Decil	Bad rate 10º decil
Regressão logística	0,6549	0,2264	34,7%	6,4%
Random Forest	0,6595	0,2247	36,1%	5,9%
XGBoost	0,6714	0,2470	38,0%	5,1%
LightGBM	0,6748	0,2530	37,9%	5,0%
Catboost	0,6757	0,2518	37,9%	4,8%

Na métrica *KS*, o melhor desempenho foi registrado pelo LightGBM (0,2530), enquanto o Random Forest apresentou o menor valor (0,2247). Os três últimos modelos apresentaram os melhores desempenhos em termos de *AUC*, com destaque para o CatBoost, que alcançou o maior valor (0,6757). Por outro lado, a Regressão Logística obteve o menor *AUC* (0,6549), embora ainda próximo dos demais. A figura 4 representa graficamente a curva ROC dos 5 modelos, onde é possível observar a maior distância entre os modelos de “boosting” e os modelos de regressão logística e “random forest”.




Figura 4. Curva ROC dos modelos desenvolvidos.

Fonte: Dados originais da pesquisa

Na análise da separação por decil, o “random forest” foi o modelo mais eficaz em identificar o grupo de maior risco, com um “bad rate” de 38% no pior decil, enquanto o CatBoost destacou-se na identificação do grupo de menor risco, com apenas 4,8% de inadimplência no melhor decil. A figura 5 representa graficamente o percentual de inadimplentes (“bad”) por decil de cada modelo. É possível observar que todos apresentaram resultados satisfatórios, separando o público em 10 grupos, onde quanto maior o “score”, menor o percentual de inadimplentes.




Figura 5. Percentual de inadimplentes por decil e modelo.

Fonte: Dados originais da pesquisa

De modo geral, os modelos baseados em “boosting”, especialmente o CatBoost, apresentaram desempenho superior nas três métricas avaliadas. O CatBoost se destacou com o melhor valor de AUC e o segundo melhor valor de KS, além de ter sido o modelo mais eficaz na identificação do decil com o menor percentual de inadimplentes. Além disso, tanto o CatBoost quanto o LightGBM oferecem vantagens adicionais no pré-processamento dos dados, pois lidam diretamente com variáveis categóricas, dispensando a aplicação de “One-Hot Encoding”, necessária nos demais modelos utilizados no estudo. Embora esses modelos mais complexos apresentem ganhos significativos em desempenho, é importante ressaltar que também demandam maior atenção quanto à otimização de hiper parâmetros, tempo de processamento e explicabilidade, aspectos relevantes na escolha do modelo para aplicação prática. Apesar dos ganhos de desempenho do CatBoost, o tempo para otimização de hiper parâmetros foi o maior entre os 3 algoritmos de “boosting”, levando 4 horas e 53 minutos. Os algoritmos de LightGBM e Xgboost levaram 8,3 e 15,4 minutos, respectivamente.

O modelo Random Forest, embora tenha desempenho inferior aos algoritmos de “boosting”, apresentou resultados superiores à Regressão Logística tanto em AUC quanto no “bad rate” do pior decil (36,1% versus 34,7%). Seu desempenho em KS (0,2247), no entanto, foi a mais baixa entre os modelos avaliados. Apesar disso, o Random Forest ainda se mostrou eficiente na segmentação de risco, com distribuição dos maus pagadores de forma consistente ao longo dos decis. Além disso, apresenta a vantagem de ser mais robusto à

presença de variáveis colineares e relativamente simples de implementar, sendo uma boa alternativa intermediária entre modelos lineares e modelos de “boosting” em contextos com menor demanda computacional.

Já a Regressão Logística, embora tenha apresentado o menor valor de KS entre os modelos avaliados, permanece como uma ferramenta amplamente utilizada em modelagem de risco de crédito, especialmente por sua simplicidade, velocidade de execução e alta explicabilidade. Esses atributos fazem dela uma escolha atrativa em ambientes regulatórios, onde a transparência e explicabilidade dos modelos são requisitos fundamentais. Além disso, sua estrutura linear facilita a comunicação dos resultados com áreas de negócio.

Conclusão

Com base na comparação entre os cinco modelos desenvolvidos, observou-se que os algoritmos baseados em “boosting”, especialmente o CatBoost e o LightGBM, apresentaram o melhor desempenho nas métricas avaliadas, sendo mais eficazes na separação entre bons e maus pagadores. O CatBoost se destacou como o modelo com maior AUC e melhor capacidade de identificar o grupo de menor risco, enquanto o LightGBM obteve o melhor valor de KS. Apesar disso, esses modelos demandam maior tempo de processamento e esforço na etapa de otimização dos hiper parâmetros, o que pode representar um obstáculo em contextos de aplicação em larga escala ou com restrições operacionais. O Random Forest, embora tenha desempenho mais modesto, mostrou-se uma opção robusta com menor complexidade de parametrização. Já a Regressão Logística, mesmo com resultados inferiores nas métricas preditivas, se mantém relevante pela sua simplicidade, rápida implementação e alta explicabilidade, sendo especialmente útil em ambientes onde seja necessário explicabilidade nas variações dos modelos. Assim, a escolha do modelo ideal dependerá do equilíbrio entre desempenho, transparência e viabilidade operacional.

Agradecimentos

Agradeço aos meus pais, Leandro e Elisandra, pelo amor incondicional, por me orientar, e proporcionar educação e todos os meios necessários para esta conquista. À Rafaela, pelo incentivo, paciência e companheirismo que tornou a jornada mais leve. Estendo também meus agradecimentos a todos os professores do curso, que contribuíram com seu conhecimento e dedicação para minha formação, e, em especial, ao meu orientador Guilherme, cuja orientação, foi fundamental para a realização deste trabalho.

Referências

- Akiba T.; Sano S.; Yanase T.; Ohta T.; Koyama M. 2019. Optuna: A next-generation hyperparameter optimization framework. In: Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York NY USA: Association for Computing Machinery, p. 2623–2631.
- Anand N. et al. 2021. Feature selection on educational data using Boruta algorithm. *International Journal of Computational Intelligence Studies* 10(1): 27–35.
- Bentéjac C.; Csörgő A.; Martínez-Muñoz G. 2021. A comparative analysis of gradient boosting algorithms. *Artificial Intelligence Review* 54. <https://doi.org/10.1007/s10462-020-09896-5>.
- Bello O.A. 2023. Machine learning algorithms for credit risk assessment: An economic and financial analysis. *International Journal of Management and Technology* 10(1): 109–133. <https://doi.org/10.37745/ijmt.2013/vol10n1109133>.
- Bhalaji N.; Kumar K.S.; Selvaraj C. 2018. Empirical study of feature selection methods over classification algorithms. *International Journal of Intelligent Systems Technologies and Applications* 17(1–2): 98–108.
- Bouke M.A.; Zaid S.; Abdullah A. 2024. Implications of data leakage in machine learning preprocessing: A multi-domain investigation.
- Breiman L. 2001. Random forests. *Machine Learning* 45: 5–32.
- Brown I.; Mues C. 2012. An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications* 39(3): 3446–3453.
- Cao D.S.; Xu Q.S.; Liang Y.Z.; Zhang L.X.; Li H.D. 2010. The boosting: A new idea of building models. *Chemometrics and Intelligent Laboratory Systems* 100(1): 1–11.
- Carrizosa E.; Del Rio C.M.; Romero Morales D. 2021. Mathematical optimization in classification and regression trees. *TOP* 29(1): 5–33.
- Coelho F.F.; Amorim D.P.L.; Camargos M.A. 2021. Analisando métodos de machine learning e avaliação do risco de crédito. *Revista Gestão & Tecnologia* 21(1): 89–116.
- Cuong N.T.; Phan H.T.; Hong T.; An B. 2025. Credit risk prediction with corruption perception index: Machine learning approaches. *Cogent Business & Management* 12.
- Dastile X.; Celik.; Potsane M. 2020. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing* 91:
- Friedman J.H. 2001. Greedy function approximation: A gradient boosting machine. *Annals of Statistics* 29(5): 1189–1232.
- Führ F. 2018. Proposição de modelos de previsão de risco de crédito para pequenas e médias empresas por meio da regressão logística. *Dissertação de Mestrado em Engenharia*

de Produção e Sistemas. Universidade Tecnológica Federal do Paraná Pato Branco PR Brasil.

Hartmann J. 2019. Classification using decision tree ensembles. SSRN.

Hosmer D.W.; Taber S.; Lemeshow S. 1991. The importance of assessing the fit of logistic regression models: A case study. American Journal of Public Health 81(12): 1630–1635.

Kanaparthi V.K. 2023. Examining the plausible applications of artificial intelligence & machine learning in accounts payable improvement. FinTech 2(3): 1–14.

Louzada F.; Ara A.; Fernandes G.B. 2016. Classification methods applied to credit scoring: Systematic review and overall comparison. Surveys in Operations Research and Management Science 21: 117–134.

Montevecchi A.A.; Miranda R.C.; Medeiros A.L.; Montevecchi J.A.B. 2024. Advancing credit risk modelling with machine learning: A comprehensive review of the state-of-the-art. Engineering Applications of Artificial Intelligence 137.

Nadizadeh Shorabeh S.; Neysani Samani N.; Minaei F.; Firozjaei H.; Homaei M.; Darvishi Boloorani A. 2022. Developing a decision model based on decision tree and particle swarm optimization algorithms to identify optimal locations for solar power plants construction in Iran. Renewable Energy 187.

Nakamura K.G. 2013. Multicolinearidade em modelos de regressão logística. Dissertação de Mestrado em Estatística. Instituto de Matemática e Estatística, Universidade de São Paulo São Paulo SP Brasil.

Ohtoshi C. 2003. Uma comparação de regressão logística, árvores de classificação e redes neurais: analisando dados de crédito. Dissertação de Mestrado em Estatística. Instituto de Matemática e Estatística, Universidade de São Paulo São Paulo SP Brasil.

Raschka S. 2015. Python machine learning. Packt Publishing Ltd [s.l.].

Satchidananda S.S.; Simha J.B. 2006. Comparing decision trees with logistic regression for credit risk analysis. International Institute of Information Technology.

Suhadolnik N.; Ueyama J.; Da Silva S. 2023. Machine learning for enhanced credit risk assessment: An empirical approach. Journal of Risk and Financial Management 16(12): 496.

Stock, A., Gegr, E.J. & Chan, K.M.A. 2023. Data leakage jeopardizes ecological applications of machine learning. Nat Ecol Evol 7, 1743–1745.

Tekić D.; Mutavdžić B.; Milić D.; Novković N.; Zekić V.; Novaković T. 2021. Credit risk assessment of agricultural enterprises in the Republic of Serbia: Logistic regression vs discriminant analysis. Ekonomika Poljoprivrede 68: 881–894.

Vieira L. 2023. Risco de crédito e a aplicação da modelagem regressão logística. Dissertação de Mestrado em Matemática. Universidade Estadual Paulista.

Yousaf M.; Shah S.; Ali S.; Chaudhry H.; Yousaf A.; Aziz K.; Hashmat K.; Akram M. 2024. Machine learning-based multi-factorial genetic disorder prediction system. Journal of Computing & Biomedical Informatics 8.

Zheng W. 2019. Kolmogorov-Smirnov type tests under spatial correlations. Dissertação de Doutorado. The Texas Medical Center Library.