

MBA EM **DATA SCIENCE E ANALYTICS**

Social Network Analysis II

Professora Adriana Silva

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Revisando

- O que é?
 - Dados/informações
 - Contexto / Exemplos
 - Tipos de Redes
 - Comunidades
 - Papéis
- Métricas
 - Degree
 - Degree Ponderado
 - Clustering Coefficient
 - Closeness
 - Betweenness

Métricas da Rede

Estatísticas Gerais

- Diversas estatísticas podem ser calculadas para as redes e para os nós das redes :
 - **Nós:** número de nós no gráfico ($|N|$)
 - **Arestas:** número de links no gráfico ($|A|$)
 - **Densidade do grafo:** o número de links em um gráfico ($|A|$) dividido pelo número total de links no gráfico completo ($|N| (|N| - 1)$)
 - **Comprimento médio do caminho:** soma dos menores caminhos dividido pela quantidade de menores caminhos
 - **Excentricidade:** distância do nó em questão até o nó mais distante dele na rede (dentre os menores caminhos, o maior)
 - **Raio:** menor excentricidade
 - **Diâmetro da Rede:** maior excentricidade (maior peso dentre os menores caminhos)

Gephi

Software Livre

- “Gephi é uma plataforma interativa de visualização e exploração de todos os tipos de redes e sistemas complexos, grafos dinâmicos e hierárquicos.”
- É um software escrito em Java e roda tanto no Windows, Linux e Mac.



- Atividade:
 - Inicializar o software
 - Conhecer o software
 - Construir a rede feita à mão
 - Extrair os resultados


Software Gephi

Introdução

- O passo a passo a seguir detalha como utilizar o Gephi a partir de bases csv, ou para criação de redes dentro do próprio software.

Simone Rossetti Nobre Naxara 224.455.198-96

Software Gephi



Software Gephi

Introdução


1. Tool Bar: atalhos para análises, visualizações de janelas, configurações, salvar, ...
2. Visão Geral: onde visualiza-se o gráfico e as métricas que podem ser calculadas
3. Laboratório de dados: onde visualiza-se as tabelas criadas
4. Visualização: onde visualiza-se o grafo para exportação
5. Partição ou Classificação: janela onde pode-se pintar ou estipular tamanhos de nós ou links, a partir de alguma métrica (como modularidade, degree, closeness,...)
6. Layout: janela para melhorar a forma de visualização do grafo baseado em algum algoritmo

Software Gephi

Introdução

7. Grafo: janela para visualização da sua rede
8. Contexto: Informações sobre sua rede (número de nós e links)
9. Estatísticas: métricas disponíveis para cálculo da rede

Software Gephi



Software Gephi

Introdução


1. Aba Nós ou Arestas: Mostra a tabela de nós ou tabela de links, conforme sua seleção
2. Adicionar nó ou Adicionar arestas: ícones utilizados para construção da rede dentro do próprio software
3. Importar planilha ou Exportar tabela: ícones utilizados para inserção ou extração das tabelas de nós ou links.
4. Atalhos para manipulação de dados: duplicar colunas, criar novas variáveis, etc...

Software Gephi




- Para abrir uma base de links ou nós a partir de um csv, ir pelo atalho de “Novo projeto”
- Para abrir arquivos .net, .gdf, .gephi utilizar o atalho “Abrir arquivo”

Software Gephi




- Na aba "Laboratório de Dados" ir na opção "Importar planilha" para abrir um arquivo csv.
- O arquivo csv deve conter no mínimo os campos "Source" e "Target". Pode conter o campo "weight" desde que este seja um campo numérico dentro do csv.

Software Gephi



- Em Import Spreadsheet, você seleciona seu arquivo e especifica se é uma tabela de nós ou links.

Software Gephi



- Ao finalizar a base é inserida dentro do Gephi e os pontos são criados para visualização.

Gephi

Exercício
com
professora

Software Livre

- “Gephi é uma plataforma interativa de visualização e exploração de todos os tipos de redes e sistemas complexos, grafos dinâmicos e hierárquicos.”
- É um software escrito em Java e roda tanto no Windows, Linux e Mac.



- Atividade:
 - Inicializar o software
 - Conhecer o software
 - Construir a rede feita à mão
 - Extrair os resultados

CONTEÚDO PROGRAMÁTICO

Tópicos:

- O que é SNA
 - Para que serve
 - Como aplica
 - Estrutura de dados
- Conceitos e teoria sobre a técnica
 - Tipo de redes
 - Comunidades
 - Papéis
- Cálculos na mão para entendimento das métricas
 - Métricas de Centralidade
 - Degree
 - Clustering Coeficient
 - Closeness
 - Betweenness
- Comunidade
 - Resolution List
 - Layouts
- Aplicação em Gephi, para entendimento e compreensão
- Python para SNA
- Exercícios

Detecção de Comunidades


Comunidades - Modularidade

- *Comunidades*
 - *Community detection* particiona uma rede em comunidades, onde os links dentro da comunidade são mais fortes que os links entre comunidades.

Detecção de Comunidades

Comunidades - Modularidade

- Como identificar uma comunidade



■ Modularidade

- É a métrica mais popular para detecção de comunidades. É uma métrica sobre a qualidade da divisão.
- Modularidade é a fração entre os links que estão dentro da comunidade menos a fração esperada se os links fossem divididos aleatoriamente (se a comunidade fosse criada aleatoriamente).

Detecção de Comunidades

Comunidades - Modularidade

- Modularidade

$$Q = \frac{1}{2w} \sum_{(u,v) \in A} \left(w_{uv} - \frac{w_u w_v}{2w} \right) \Delta(C_u, C_v)$$

$$w = \sum_{(u,v) \in A} w_{uv}$$

$$w_u = \sum_{v \in \delta_u} w_{uv}$$

onde Q é a modularidade

w_{uv} é o peso do links entre os nós u e v .

δ_u é o universo de nós que contém o nó u .

w_u é a soma dos pesos dos links que tem u .

w é a soma dos links da rede.

C_u é a comunidade que tem u .

$\Delta(C_u, C_v)$ é o delta definido como: $\Delta(C_u, C_v) = \begin{cases} 1, & \text{se } C_u = C_v \\ 0, & \text{caso contrário} \end{cases}$

Detecção de Comunidades

Comunidades - Modularidade

- Tem sido frequentemente observado, na prática, que o número de nós contidos em comunidades (produzido por algoritmos de detecção de comunidade) geralmente segue uma distribuição da lei de potência, isto é, algumas comunidades contêm um número muito grande de nós, enquanto que a maioria das comunidades contêm um pequeno número de nós. Isto é especialmente verdadeiro para redes de grandes dimensões.

Detecção de Comunidades

Comunidades - Modularidade

- Resolução
 - O valor atribuído a esta opção pode ser interpretado da seguinte forma:
 - Suponha que o valor do Resolução seja x . Duas comunidades são mescladas se a soma dos pesos dos links inter-relações da comunidade é de pelo menos x vezes o valor esperado da mesma soma se o gráfico é reconfigurado de forma aleatória.
 - Portanto, um valor menor de Resolução produzirá mais comunidades contendo um número menor de nós. No entanto, não existe uma fórmula explícita detalhando o número de nós nas comunidades com relação ao valor de resolução.
 - Deve-se usar tentativa e erro para chegar ao tamanho da comunidade esperada.
 - Utilize valores menores para gerar comunidades menores e valores maiores de 1 para gerar menos comunidades maiores.


Exercício
com
professora

Dados:
karate.xlsx

Não esqueça de
importar como uma
tabela de links!!!

Exemplo: Detecção de comunidade nos dados de um clube de Karate

- Este exemplo usa os dados de uma escola de Karate, que descreve a rede social entre 34 membros de um clube de karate em uma universidade dos EUA na década de 1970. Este é um banco de dados público, muito usado para testes de detecção de comunidades. Ele contém 34 nós e 78 ligações.
- Dado os dados, execute a as comunidades no Gephi. Teste diferentes resolutions.



Python

Software Livre

- A biblioteca mais comum e mais utilizada em grafos é a igraph
 - Atividade:
 - Explorar os códigos Python
 - » `1_SNA_conhecendo_codigos_Python.py`

Comunidades – igraph



Algoritmos de detecção de comunidade

Uma lista de algoritmos disponíveis no IGraph inclui:

- Modularidade Ótima
- Edge Betweenness (2001)
- Fast Greedy (2004)
- Walktrap (2005)
- Eigenvectors (2006)
- Spinglass (2006)
- Propagação de rótulo (2007)
- Multi-nível (2008)
- Mapa de informações (2008)

Comunidades – igraph

Resumo

- Para gráfico direcionado: vá com **Info Map**.
- Se os recursos computacionais não forem um grande problema, e o gráfico for <700 vértices e 3500 arestas, escolha **Edge Betweenness**; produz o melhor resultado.
- Se se preocupa com a modularidade, qualquer um dos algoritmos restantes será aplicado;
 - Se o gráfico for particularmente pequeno: <100 vértices, use **optimal modularity**;
 - Se você quiser um algoritmo de primeira tentativa, use **fast greedy** ou **walktrap**
 - Se o gráfico for maior que 100 vértices e você quiser algo mais preciso do que **fast greedy** ou **walktrap**, use o **leading eigenvectors**
 - Se você estiver procurando por uma solução semelhante ao agrupamento K-means, vá para o **Spinglass**

Fonte: <https://yoyoinwanderland.github.io/2017/08/08/Community-Detection-in-Python/>

Python

Software Livre


- A biblioteca mais comum e mais utilizada em grafos é a igraph
 - Brincarmos com as comunidades
 - » `2_SNA_exemplo_comunidades_base_Karate.py`

Python

Software Livre

- A biblioteca mais comum e mais utilizada em grafos é a igraph
 - Como extrair métrica por comunidade?
 - » `3_SNA_exemplo_comunidades_base_karate.py`

Processo de SNA (sugestão): “passo a passo”



Referências Bibliográficas

- PINHEIRO, C. A. R. **Social Network Analysis in Telecommunications**. USA: John Wiley, 2011, 284 p.
- NEWMAN, M. E. J. **Networks**: An Introduction. New York: Oxford, 2010, 772 p.

Obrigada!

Professora Adriana Silva | [linkedin.com/in/adrianamms](https://www.linkedin.com/in/adrianamms)

MBAUSP
ESALQ